


Linear regression

baseline: mäs dātā (X_i, Y_i)
 hlādās priamā $\hat{y} = b_0 + b_1 x$
 intercept (kde priamā pāriešas 4 ($x=0$))
 Slope (ar kādu slīksni y , kad x stupne 01
 $b_1 = \frac{\Delta y}{\Delta x}$
 priamā parametrs

to sa hlādā pāmā leat spāš



baseline hlāt b_0, b_1

Barosovskā LR:

abē sū pāmāpāmā hlādā b_0, b_1
 parametrs sū mātāmā pāmā


$\hat{y} = b_0 + b_1 x$ → dātā reālā mēlā mātā mātā
 + šūn $\hat{y} = b_0 + b_1 x + \epsilon$ → mātā $\epsilon \sim N(0, \sigma^2)$

mean squared residuals


• Priemā/mām = 0 → Chyba je symetrisā
 (priemā rozdel mātā skatāmā Y a mātāmā $\hat{Y}$ je 0

$\epsilon_i = y_i - (b_0 + b_1 x_i)$


vertikālā vārdāmā
 mātā skatāmā (x_i, y_i)
 a hlādā mātā pāmā pri
 Rozmā x





⇒ mean(mātā erorā) = (+2)



⇒ mean = (-2)



⇒ mean = 0



$r = [-1, 2, -3, 1]$
 $\bar{r} = \frac{-1+2-3+1}{4} = -\frac{1}{2}$
 Priemā mātā hlādā.

$OCHYLA = [r_i - \bar{r}]$
 1 → $-1 - (-\frac{1}{2}) = -\frac{1}{2}$
 2 → $2 - (-\frac{1}{2}) = \frac{5}{2}$
 3 → $-3 - (-\frac{1}{2}) = -\frac{5}{2}$
 4 → $1 - (-\frac{1}{2}) = \frac{3}{2}$

Chyba > 0
 $[2.25, 2.25, 12.25, 12.25]$
 $\sigma^2 = \frac{2.25 + 2.25 + 12.25 + 12.25}{4} = 7.25$
 $\sigma^2 = 7.25$


Least squared dá bodový odhad.
 Bayes dá rozdelenie a meštotu.

$$P(d, \beta | D) = \frac{P(D | d, \beta) \cdot P(d, \beta)}{P(D)}$$

$$P(d, \beta | D) \sim P(D | d, \beta) \cdot P(d, \beta)$$

$$Y \sim N(\mu = d + \beta x, \sigma)$$


mean is
 distributer around line



of insted

$$y = d + \beta x$$

insted we
 want
 PDF (conf?)



* example na pochopenie

→ chceme modelovať ako počet hodín učenia odpovedá výsledok testu

Počet hodín učenia X	Výsledok Y
2	5
10	1

↓ model

$$Y_i \sim N(\mu_i, \sigma)$$

očekávaná hodnota

↓ každý μ_i je pre 1 datapoint X_i

$$\mu_i = d + \beta x_i$$

A je vypočítaný pomocou d, β

→ pre každý X_i sa vypočíta jeho očekávaná hodnota μ_i

$$\begin{aligned} \mu_1 &= \mu + \beta \cdot 2 \rightarrow 5 \sim N(\mu + \beta \cdot 2) \\ \mu_2 &= \mu + \beta \cdot 10 \rightarrow 1 \sim N(\mu + \beta \cdot 10) \end{aligned}$$

likelihood

→ chceme nájsť také μ a β aby boli
naše dáta "pravdepodobné"
pravdepodobnosť pozorovania $Y=5$ je

$$p(5 \mid \mu, \beta, \sigma)$$

likelihood: $p(\text{data} \mid \mu, \beta, \sigma)$

$$\downarrow$$

$$p(5 \mid \mu, \beta, \sigma) \times p(1 \mid \mu, \beta, \sigma)$$

↪

aká je pravdepodobnosť, že sú dáta keď zvolíme μ, β

Random μ, β

napr. $\mu = 6, \beta = -0.5$

$$\mu_1 = 6 - 0.5 \cdot 2 = 5$$

$$\mu_2 = 6 - 0.5 \cdot 10 = 1$$

	$\mu =$
5	5
1	1

Perfect match

↪

likelihood bude veľký

TAKÉ HLADIS také μ, β aby
 μ_1 bolo čo najviac μ Y_i

CLASSIC

↓

μ, β kt.

mini malý
error

BAYESIAN

→ pries: tieto μ, β sú viac pravdepod.
aké iné μ, β .

↪
výsledok je distribúcia
 μ, β

Príklad

libelihood: ak súhlasí architektúra d, β aká je $P()$ že som videl tieto údaje?

$$\text{teda } w_1 = 5 = \begin{bmatrix} 6 \\ 1 \end{bmatrix} \\ w_2 = 1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

perfect

PRIORS → musíme nastaviť pre každý parameter

$$d \sim \dots \text{ napr. } N(\dots)$$


$$\beta \sim \dots N(\dots)$$

$$\sigma \sim \dots$$

a) nastavíme prior pre β → Slope → o koľko sa zmení Y (známka) ak X (hodiny) porastie o 1?

- mean → stred napr. 0 ak neviete či slope môže byť + or - (tu ale vieme že bude)
- SD → odbytá. • Pozri rozsah Y
 - ak X rastie o 1, koľko maximálne môže mať Y ?
 - nastav aj poleže 95%.


↓
ak budeš študovať o 1 hodinu viac, ak sa môže zmeniť známka



↓
tu by sa mal byť kladný.
ale je to teraz lebo N

$$\beta \sim N(0, 1)$$

b) d → očakávaná hodnota Y ak $X=0$



⇒ ak študuje 0 hod
↓
čakávaná (5)

$$d \sim N(5, 1)$$

mám σ -Priors ✓

BATES
↓

Posterior $\propto$ likelihood $\times$ prior

↓
dostanem distribuci
 $p(\alpha, \beta \mid \text{data})$

Prior predictive check: Vyberme si priors.

↘ Na nich generujeme FAKE DATA Aby

Shle videli ci dajeme priors zrych.


↳ INFER THE POSTERIOR



Kedze hovime vypostat hodnoty pre kazde $\alpha, \beta,$


tak samplingem.

NOTE !!



→ Po vsetknom nime pravdepodobie d, β, σ .

(test?) Posterior - predictive check



→ Posterior - predictive Qd

⊕ prióri obrázky atd...