Multiple regression – viacnásobná regresia

(Používanie regresiu skôr na porozumenie vzťahov, nie len na predikciu

- exponentional distribution: (používa sa na časy čakania medzi udalosťami) sú prichádzajúci metódu
- Corelation is <u>not</u> causation: ak X rastie a Y rastie, ešte neznamená že X spôsobuje Y. ⟵ Z ? / random
- Confounding: (tretia premenná): ak X a Y korelujú, ale v skutočnosti Z ovplyvňuje X aj Y a Z nepridáš do modelu.
- Counter factuals: čo by sa stalo s Y ak by som zmenil X, a všetko ostatné by bolo rovnaké?
- Masking: opak confoundingu → efekt existuje ale nevidíš ho.

NAPR.

	NO TRAIN	TRAIN
MAN	45 min	40 (-5)
WOMAN	55 min	50 (-5)

} ak nevieš POHLAVIE
↓
AVG(TRAIN) = 50m
AVG(NO TRAIN) = 48m
↗ BLBOSŤ že?

- Categorical values: premenné, kt. nie sú čísla. → v regresii ich musíš zakódovať.

Exponential distribution

modeluje čas čakania do udalosti (waiting time)
definované len pre kladné hodnoty > 0

PDF
$$\boxed{p(x) = \lambda e^{-\lambda x}}$$

$\lambda \geq 0$ rate (rýchlosť/intenzita udalostí)
väčšie λ ⇒ typicky kratšie čakanie. (udalosti sú častejšie)

mean, variance →

- mean $\boxed{E[x] = \frac{1}{\lambda}}$
- SD $\boxed{SD(x) = \frac{1}{\lambda}}$
- variance $\boxed{var(x) = \frac{1}{\lambda^2}}$

Support is positive ⇒ distribution dáva ne-nulovú pravdepodobnosť len pre $x \geq 0$

Maximum entropy distribution:

- vieš iba „typická veľkosť je okolo niečoho"
- nedáš pridávať predpoklady
  tak exponenciála je neutrálna voľba

$\boxed{\sigma \sim exp(1)}$ znamená že očakávané odchýlky 1, ale nevieme nič viac avg

DATA STANDARDIZATION

↳ z každej číselnej premennej spravíš „rovnaké miery"

Kedy:? - Viac prediktorov s rôznymi jednotkami (vek, príjem...)
- aj bayes reg. (lebo musíme nastaviť PRIORS.)

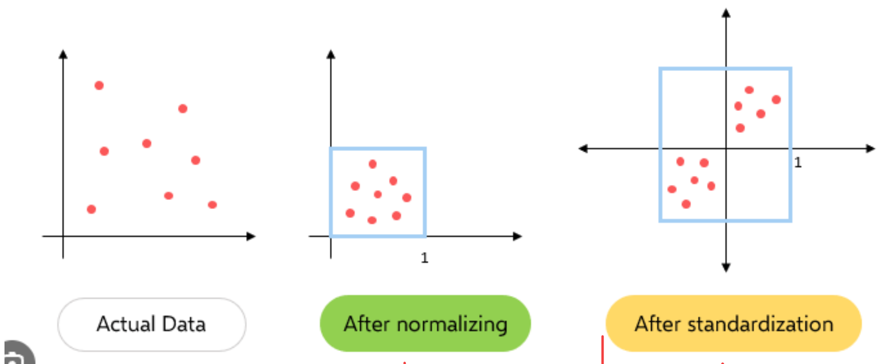

After normalizing

↓ dáta budú v [0,1]

napr.

Salary	Normalized
20 000	$\frac{20\,000-20\,000}{100\ldots-20\ldots}=0$
50 000	$\frac{50k-20k}{100k-20k}=0.37$
100 000	$\frac{100k-20k}{100k-20k}=1$

$$\boxed{norm(x)=\frac{x-min}{max-min}}$$

After standardization

↓ mean 0

SD 1

↳ len znova scale

$$\mu=\frac{20k+50k+100k}{3}=56k$$

$$SD=32k$$

$$z\ score=\frac{x-\mu}{SD}=$$

Salary ↓	Stand.
20k	$\frac{20k-56k}{32k}=-1.11$
50k	-0.2
100k	1.31

Kedy?

↓ ak treba pevný interval.
ktoré alg.
→ NEURÓN, ...

→ regresia/bayes/
- regularizácia
- MCMC

Default

ale často štandardizujeme aj (Y)

takže napr.

divorce_std ~ marriage_std + MedianAgeMarriage_std

aj σ a priors budú na rovnakej škále.

Zatiaľ

- Pozreli sme sa na dáta
- Standardizovali sme
- Špecifikovali sme model
- Zvolili sme priory a, b, σ
  a prior predictive check
- FIT MODELU MCMC (with model, a.. b.. sp.. MCMC)

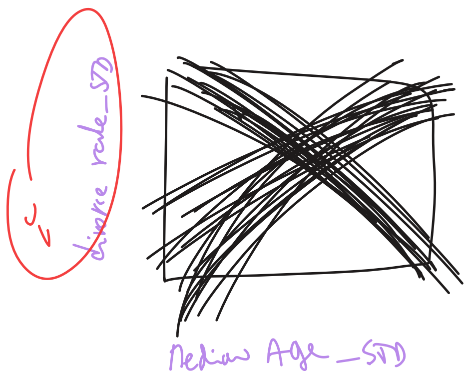

- Posterior vizualizácia

a) Divorce rate ~ Median age model

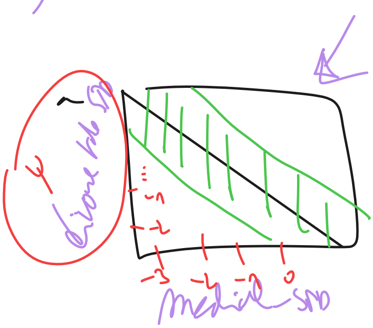

A v STD

b) Divorce rate ~ Marriage rate

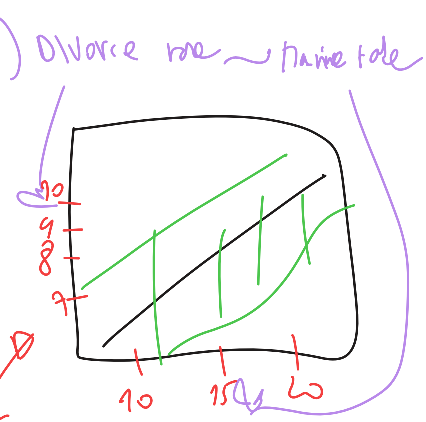

V NORMAL SCALE

takže zatiaľ máme 2 modely

1.) $Y_{STD} \sim N(\mu, \sigma)$ $\mu = \alpha + \beta_1 X1_{STD}$

median age married

a

$Y_{STD} \sim N(\mu, \sigma)$ $\mu = \alpha + \beta_2 X_{2\,STD}$

marriage_STD

obe modely niečo ukazujú.

ale nevieme či je medzi nimi correlation.

X_1 ovplyvňuje Y, alebo X_2 ovplyvňuje Y, alebo X_1 a X_2 ovplyvňuje (A+D)

Veľa možností

Ako zistiť? MULTIPLE Regresia

$$D_i \sim N(\mu_i, \sigma)$$
$$\boxed{\mu_i = \alpha + \underbrace{\boxed{\beta_1 X_{1_i}}}_{\text{model 1}} + \underbrace{\boxed{\beta_2 X_{2_i}}}_{\text{model 2}}}$$
$$\alpha \sim N(0, 0.2)$$
$$\beta_1 \sim N(0, 0.5)$$
$$\beta_2 \sim N(0, 0.5)$$
$$\sigma \sim \exp(1)$$

FIT MODEL

↓ MCMC

a = MedianAgeMarriage_std
M = Marriage_std
D = Divorce_rate_std

Sanity check (posterior, atď)

Causality Analysis with the Posterior

$D = \alpha + \beta \cdot M + \beta \cdot A$

[22]:
```
print(rt.precis(m_5_3_idata.posterior)) # bookstyle
```

```
sample: 1000 values of 5 variables
        mean    sd   5.5%   94.5%  histogram
a     -0.00   0.10  -0.16    0.17
bA    -0.60   0.16  -0.85   -0.35
bM    -0.06   0.16  -0.30    0.20
sigma  0.84   0.09   0.71    0.98
mu    -0.00   0.59  -1.03    0.88
```

a = α, bA = βA, bM = βM, sigma = σ, mu = μ

interval je celý neg. <-0.85, ... -0.35>
Ak zvýšiš A (median age) o 1 a M rovnaké, zmena v D je prene βA ~ -0.6
a ak zvýšiš M o 1, a A nedáš, tak D môže ísť (-0.3, 0.2) ~ 0
ak A ide hore, D ide dole
model má dosť veľký odchýlky ~ 0.84 => 84% neysvetlené.
-0.00 -> tak ako sme definovali

[23]:
```
az.summary(m_5_3_idata, group="posterior", var_names=["a", "bM", "bA", "sigma"], kind="stats") # the same, arviz style
```

[23]:

	mean	sd	hdi_3%	hdi_97%
a	-0.000	0.103	-0.184	0.207
bM	-0.060	0.158	-0.347	0.257
bA	-0.605	0.157	-0.898	-0.312
sigma	0.837	0.088	0.678	0.998

-> najkratší interval obsahujúci 95% posterior.

Here we have a comparison of univariate and multivariate slopes for these predictors:

```
# Create the forest plot •••
```

Forest Plot

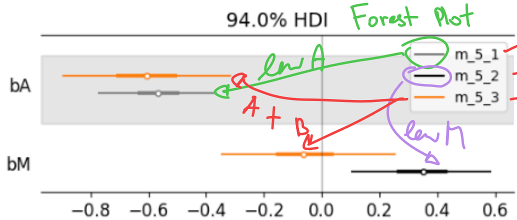

-> D ~ A
-> D ~ M
-> D ~ A + M multiregresia

- In the multivariate model (m_5_3) the posterior rate for bM is close to zero, while bA is almost unchanged comparing to m_5_1 .
- This indicates that the influence from M on D is minimal
- *"Once we know median age at marriage for a State, there is little or no additional predictive power in also knowing the rate of marriage in that state."*
- So $D \perp\!\!\!\perp M \mid A$ holds and the second causal graph (with two edges) is more likely
- **This is crazy: we used correlation analysis to decide something about causation!** And purely based on data!

a) D ~ A
bA je negatívne => vyšší vek po manželstve -> nižší divorce rate

b) D ~ M
bM je pozitívne, viac manželstiev => viac rozvodov.

c) D ~ A + M
• bA -> ostáva negatívne, aj keď kontroluješ marriage rate => A silno súvisí s divorce rate
• bM -> okolo 0 -> keď poznáš A, marriage rate už nič nepridáva

Dáva to zmysel.

Viac sobášov, viac rozvodov

NESÚVISÍ S TÝM

že čím väčší vek tým menej rozvodov

Ako zistiť čo pridáva M navyše?

$\boxed{\text{Residual plots}}$ → odstráni z M tú časť ktorú vie vysvetliť A a pozrie či súvisí s D

1.) fit → $M \sim A$ → $\hat{M}$

2.) vypočítaj residuals $M_{res} = M - \hat{M}$

3.) pozri či tieto residuals vedia Divorce.

- ak M_{res} silno súvisí s D, tak M má pridanú hodnotu aj po A
  ak nie, tak je zbytočné

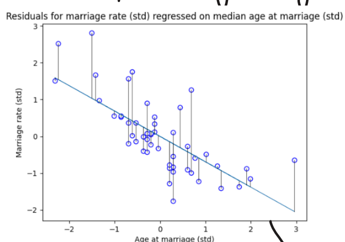

ZÍSKAŤ ČASŤ M KT. A nevysvetľuje.

res plot $M \sim A$ → regresujeme M na A

2.) added value M.
vezmeme residuals

- FITNEME REGRESIU → otestovať či zvyšok Marriage rate (to čo A nevysvetľuje) ešte vysvetľuje divorce rate

↓

či M pridáva info po A

	mean	sd	hdi_3%	hdi_97%	mcse_mean	mcse_sd	ess_bulk	ess_tail	r_hat
a	0.001	0.116	-0.217	0.211	0.001	0.002	5953.0	3432.0	1.0
bAMRes	-0.067	0.189	-0.455	0.254	0.003	0.003	5673.0	2911.0	1.0
sigma	1.029	0.103	0.837	1.224	0.001	0.002	5269.0	2965.0	1.0

→ M nepřidává prediktivní hodnotu, po A

```
x = residuals •••
```

Residual variation in marriage rate associate to divorce rate

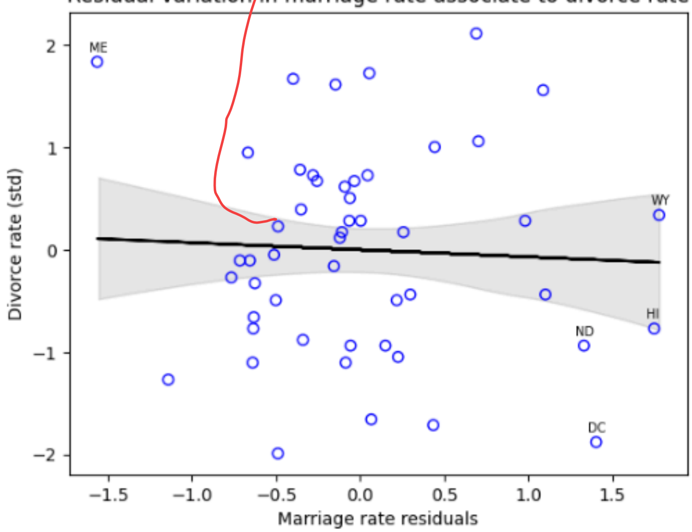

Posterior predictive check (po fitování regrese $D \sim \alpha + \beta A + \beta M$)

Posterior predictive plot - Predicted divorce rate (and 89% HDI) vs observed divorced rate

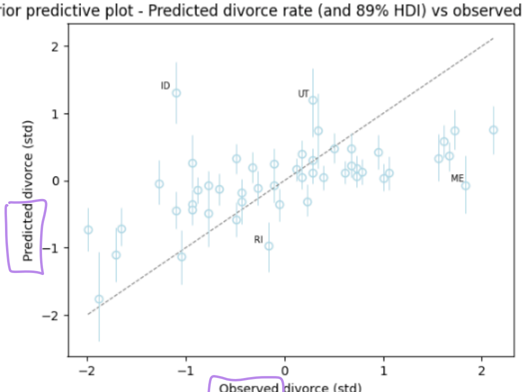

real

COUNTER FACTUALS

Zatiaľ máme model $\boxed{D \sim A + M}$ → vie rátať D ak mu dáš A, M

Counterfactual: ak zmením A, čo sa stane?

Mám

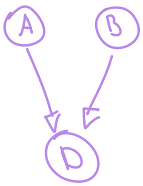

Chcem

neviem čo sa stane s M ak zmením A

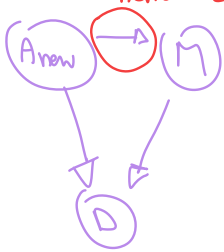

(* Podľa našich dát, by M nemalo ovplyvňovať D ale treba to počítať.)

⇓

Pridať model: $M \sim A$ → aby sa zmenilo M z A

```python
with pm.Model() as m5_3_A:

    # mutable data nodes
    M = pm.Data("M", data.Marriage_std.values, dims = "marriage_obs_id")
    A = pm.Data("A", data.MedianAgeMarriage_std.values, dims="age_obs_id")
    D = pm.Data("D", data.Divorce_std.values, dims = "divorce_obs_id")

    # A -> D <- M
    sigma = pm.Exponential("sigma", 1)
    bA    = pm.Normal("bA", 0, 0.5)
    bM    = pm.Normal("bM", 0, 0.5)
    a     = pm.Normal("a", 0, 0.2)

    mu = pm.Deterministic("mu", a + bA * A + bM * M)
    divorce  = pm.Normal("divorce", mu, sigma, observed = D)

    # A -> M
    sigmaM = pm.Exponential("sigmaM", 1)
    bAM    = pm.Normal("bAM", 0, 0.5)
    aM     = pm.Normal("aM", 0, 0.2)

    muM = pm.Deterministic("muM", aM + bAM * A)
    marriage = pm.Normal("marriage", muM, sigmaM, observed = M)

    m5_3_A_idata = pm.sample(random_seed = rng)
```

Joint (casual) model for count. Kombinuje 2 regresia into 1 gen. model.

$$
\begin{aligned}
\text{sigma} &\sim \text{Exponential}(f())\\
\text{bA} &\sim \text{Normal}(0, 0.5)\\
\text{bM} &\sim \text{Normal}(0, 0.5)\\
\text{a} &\sim \text{Normal}(0, 0.2)\\
\text{sigmaM} &\sim \text{Exponential}(f())\\
\text{bAM} &\sim \text{Normal}(0, 0.5)\\
\text{aM} &\sim \text{Normal}(0, 0.2)\\
\text{mu} &\sim \text{Deterministic}(f(\text{bM}, \text{a}, \text{bA}))\\
\text{muM} &\sim \text{Deterministic}(f(\text{aM}, \text{bAM}))\\
\text{divorce} &\sim \text{Normal}(\text{mu}, \text{sigma})\\
\text{marriage} &\sim \text{Normal}(\text{muM}, \text{sigmaM})
\end{aligned}
$$

→ $D \sim N(\mu, \sigma)$

→ $M \sim N(\mu_M, \sigma_M)$

$D \sim A + B$

$a + bA + bM \quad / \sigma, \mu$

$M \sim A$

$a_M + bAM \quad / \sigma_M, \mu_M$

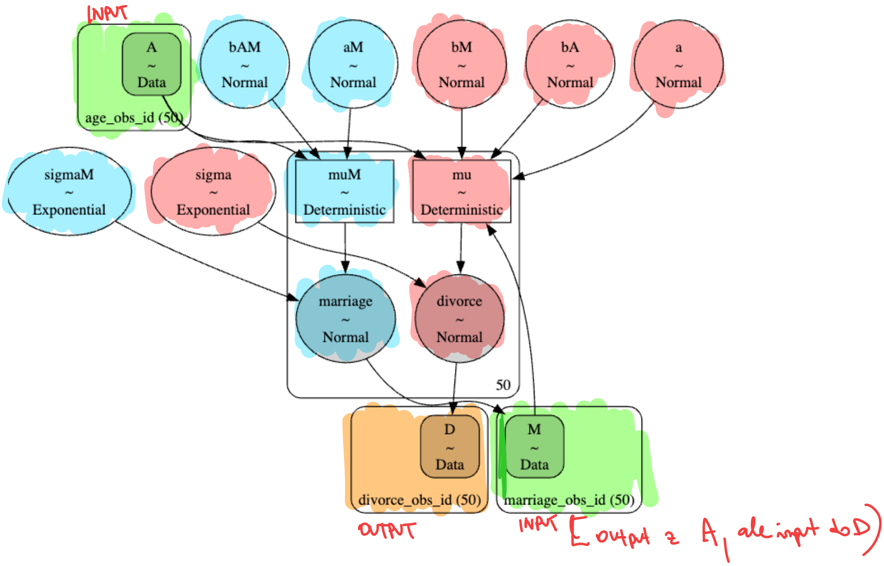

↓ counterfactual SIMULÁCIA

po fitnutí modelu (už máme prior pre parametre) nastavíme A na nový rozsah hodnôt A-seq a necháme model nasimulovať/predikovať aké M a následne D by pri takomto Novom A vyšli

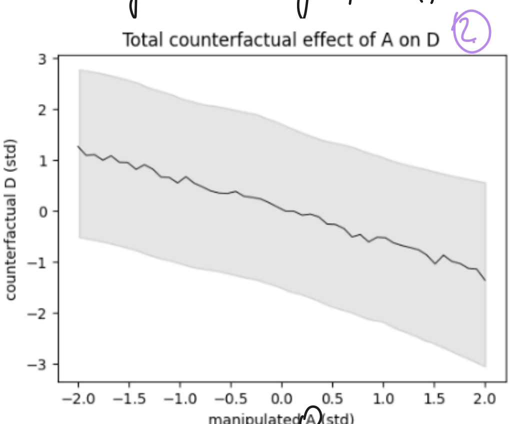

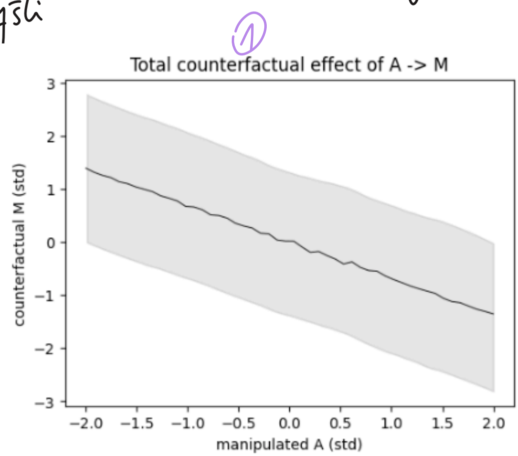

Keď umelo zvýšime A, tak model predikuje že D ide dole

vyšší vek ⇒ nižší divorce

Keď zvýšime A, model predikuje že M ide tiež dole

vyšší vek ⇒ nižší marriage rate

Masked relationship

-hidden effekt: je vplyv medzi 2 premennými ale ho nevidíš.

napr. X_1 tlačí Y hore
X_2 tlačí Y dole
ak idú naraz obe, tak Y sa bude veľmi líšiť

example: zloženie mlieka u opíc.

Chceš zistiť ako „silné" je idu mlieko (kcal per gram)

$X_1 = M$ (mass) kg	$X_2 = N$ (neokortex v mozgu) %	$Y = K$ (Kcal per gram)
1.95	55.16	0.49
5.25	64.54	0.47

1.) Standardize + drop empty rows

M	N	K
−0.52	−2.11	−0.95
−0.38	−0.54	−1.08

2.) 1. model s 1 prediktorom. $\boxed{K \sim N}$ → neokortex predikuje Kcal

$\boxed{K \sim N(\mu, \sigma)}$

$K_i \sim \text{Normal}(\mu_i, \sigma)$

$\mu_i = \alpha + \beta_N N_i$

$\boxed{a + bN \; / \; \mu \; \sigma}$

```
with pm.Model() as m5_5:
    N_mut = pm.Data("N_mut", dcc.N.values)
    sigma = pm.Exponential("sigma", 1)
    bN = pm.Normal("bN", 0, 0.5)
    a = pm.Normal("a", 0, 0.2)
    mu = pm.Deterministic("mu", a + bN * N_mut)

    K = pm.Normal("K", mu, sigma, observed = dcc.K)

    m5_5_trace = pm.sample(random_seed = rng)
```

→ Priors (zvolené podľa praktických očakávaní)

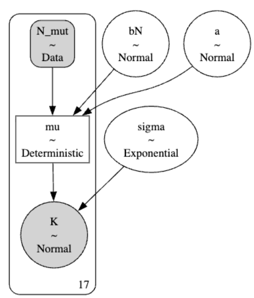

	mean	sd	hdi_3%	hdi_97%
a	0.038	0.160	-0.264	0.337
bN	$\boxed{0.130}$	0.238	-0.304	0.601
sigma	1.128	0.204	0.795	1.538

vyzerá to že N je veľmi slabý na vysvetlenie K

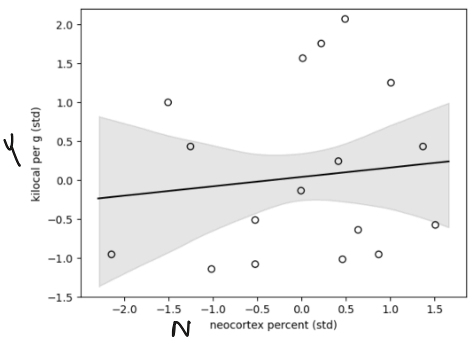

? slabota

N a M (body mass) in log

log N → K   log M → K

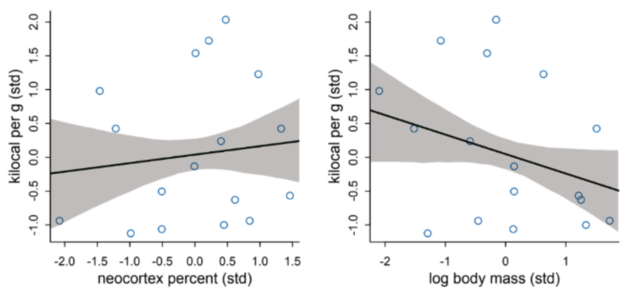

Weak associations ALONE

takže osobitne nič neukazujú. ale čo ak urobíme multiple regression?

$$\begin{tikzcd} M \arrow[rr] \arrow[dr] & & N \arrow[dl] \\ & K & \end{tikzcd} \qquad \begin{tikzcd} M \arrow[dr] & & N \arrow[ll] \arrow[dl] \\ & K & \end{tikzcd} \qquad \begin{tikzcd} M \arrow[dr] & U \arrow[l] \arrow[r] & N \arrow[dl] \\ & K & \end{tikzcd}$$

- Unfortunately we cannot decide which one is valid using correlations, as all generate the same conditional independencies.
- They are in the same **Markov Equivalence Set**
- In the end, it is not the data, but our background scientific knowledge (the big world) that stands for the correctness of these diagrams.
- Still multiple regression shown us that there are correlations from regressors to the target, even though we cannot see whether they are causal.

Categorical values:

do regresie nejdú čísla, ale kategórie môžu vysvetľovať i

example: Pridáme „Clade" →

```
array(['Ape', 'New World Monkey', 'Old World Monkey', 'Strepsirrhine'],
      dtype=object)
```

mapping

clade	clade ID
0	Ape
1	New World Monkey
2	OLD — " —
3	Strepsirrhine

$$K_i \sim \text{Normal}(\mu_i, \sigma)$$
$$\mu_i = \alpha_{\text{clade}[i]}$$
$$\alpha_j = \text{Normal}(0, 0.5) \quad \text{for j} = 1..3$$
$$\sigma \sim \text{Exponential}(1)$$

Každý Clade ID má vlastný priemer

→ zistiť či SA K systematicky líši between groups

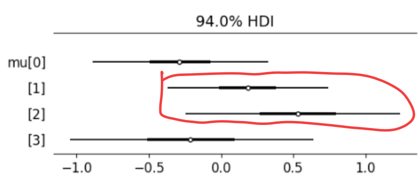

Contrast plots

- máme model s priemermi $\mu[\text{clade}]$

CONTRAST $\Rightarrow$ vezmeme posterior rozdiel: $\mu_{ape} - \mu_{New\ World\ Monkey}$

a pozrieme sa na HDI + ďal.

Priemer rozdielu -0.47

(Ape má nižší K ako NWM

ale nevieme isto že sa skupiny líšia, lebo 95% HDI ide

$\boxed{\text{cez } 0}$