

- **log-normal distribution**: ak modelujeme niečo čo nemôže byť záporné (napr. čas, peniaze) bude relatívne hodnota je malá, ale pár je extrémne veľkých
- **Multi-collinearity**: ak sú v modeli 2 veľmi podobné premenné, model môže byť menej presný $\Rightarrow$ a môže byť overfitted
- **Post treatment effect**: keď do modelu pridáš niečo čo ovplyvňuje aj pr. závislosť $\rightarrow$ môže ti potvrdiť
- **Collider bias**: Ak pozoráš len na špecifickú skupinu ľudí, môžeš si urobiť chybné závery } výsledok
myslíš si, že medzi tými ľuďmi nie je žiadna súvislosť
- **Causal coin founder framework**: jednoduchý spôsob, ako si preveriť aké premenné máš konštantné, aby si vedel, že si ich skutočne pričinou a nie následkom.


Log-Normal distribution


- hodnota ≥ 0

- väčšina hodnôt je malá (pár je veľkých)

example: Platy ľudí

X: Plat	Y: Count ľudí
5 \$	20
20 \$	20
30 \$	100
70 \$	200
100 \$	3
200 \$	1





- It is a useful distribution to use as a prior if our belief in the parameter value growth up to some point and then decreases
- Negative values are not allowed

Multi-Collinearity

silná závislost mezi 2+ proměnnými v modelu

↓ consequences:

- freedom in regression: model má velkou schopnost abstrahovat rozdíl efektu mezi 2 podobnými var.
- High variance on posteriors: Koeficienty budou mít nejistotu $\Rightarrow$ široké intervaly
- Does not harm prediction.
ale nekdo chce vidět předpovědi, která var je zodpovědná
model si nepochybně isť
která var. je zodpovědná

example: Predict height of person from length of their legs. $\rightarrow$ je třeba důkaz

a) oběh výš

b) jen 1 nohy

?

1.) Vygenerovat umělé data

- height
- leg-left = část výš + šum
- leg-right = část výš + šum
- obě nohy skoro rovnake
- obě nohy s silnou korelací

2.) Predict výšku:


$$\text{height} = a + b_L \cdot \text{leg-left} + b_R \cdot \text{leg-right}$$

Použit obě nohy naraz $\rightarrow$ také model nebude vidět
noha vysvětluje. $\Rightarrow$ nevíme
kt. rozdíl efekt.


	mean	sd	hdi_3%	hdi_97%
a	0.78	0.27	0.26	1.27
bl	0.45	2.05	-3.42	4.28
br	1.59	2.05	-2.24	5.46
sigma	0.57	0.04	0.49	0.64

→ bl, r majú obrovské intervaly ⇒ model si vôbec nie je istý id hodu.


↓
sigma je malá a interval je nízky ⇒ model predikuje výšku veľmi dobre
↓
chyba je malá



Podime porovnať Právú nohu VS P+L nohu



↓
individuálne
veľmi
veľké



↓
Spoločne
Super

Prí multicolinearity sú individuálne koeficienty neidentifikovateľné, ale ich súčet je stabilný a dobre určujú

example 2: Chceme predikovať Kcal/g (energia mlieka).

Pomocou: perc.fat
: perc.lactose

a) model vzlášť

① $Kcal \sim fat$

	mean	sd	5.5%	94.5%
a	0.00	0.08	-0.12	0.12
bF	0.86	0.08	0.73	1.00
sigma	0.45	0.06	0.36	0.54

→ úzky !!

silný poz. efekt fatu na kcal

② $Kcal \sim lactose$

	mean	sd	5.5%	94.5%
a	0.00	0.07	-0.11	0.11
bL	-0.90	0.07	-1.02	-0.79
sigma	0.38	0.05	0.30	0.46

→ úzky !!

silný neg. efekt lactose na kcal

oba vzťahy dobre (úzke intervaly)

⇓

vzťahá to, že sú dva dôležité

model spoločný: $Kcal \sim fat + lactose$


	mean	sd	5.5%	94.5%
a	0.00	0.07	-0.11	0.11
bF	0.24	0.18	-0.05	0.54
bL	-0.68	0.18	-0.97	-0.38
sigma	0.38	0.05	0.30	0.46

obsahujú 0 !!

neistota vzťahu

efekt veľmi slabý

Scatter plot:




⇓
ak lacto sa rastie,
fat klesá

a
OPAKUJE

Post treatment bias $\rightarrow$ chýba štrná variabla ak do modelu pridaš premenú štrná variabla až po zásahu (treatment).

example: chasť zistiť či štúdiu pomáha pre lepšiu známosť.
+ ale pridaš do modelu úhynu
 $\downarrow$
úhynu vzniká pri včeni

example 2: Pestujeme rastliny: meráme: h_0 : pozit. výška
 h_1 : divná výška
 T = treatment (napr. chemikálie)
 F = prítomnosť plesne
má T (+treatment) vplyv na výšku h_1 ?
Treatment má sa cíti $\rightarrow$ znížiť plesne (F)



Chyba: ak spraviš model $h_1 \sim T + F$ tak srovnáš F , ale F je dôsledok T .
takže čiast model odstraňuje
čiast efektu T

$\Rightarrow$ NIKDY NEKONTROLUJ VARIAB. VNIKA PO ZÁSAHU.

1.) ģen. < sintētiskā datu

	mean	sd	hdi_3%	hdi_97%
h0	10.24	2.04	6.96	14.13
h1	14.52	2.55	9.22	18.46
treatment	0.50	0.50	0.00	1.00
fungus	0.30	0.46	0.00	1.00

priemā h0 je 10.24

↳ priemā fināl h1 je 14.52

↳ 50% mā treatment

↳ 30% rastlīnu mā plesē

```
# number of plants
N = 100
# simulate initial heights
h0 = np.random.normal(10, 2, N)
# assign treatments and simulate fungus and growth
treatment = np.repeat([0, 1], N / 2)
# fungus develops with 50% chance, but only 10% under treatment
fungus = np.random.binomial(n=1, p=0.5 - treatment * 0.4, size = N)
h1 = h0 + np.random.normal(5 - 3 * fungus, size = N)

# Let's put it all into a DataSet object
d = xr.Dataset(
    {
        "h0": ("index", h0),
        "h1": ("index", h1),
        "treatment": ("index", treatment),
        "fungus": ("index", fungus)
    },
    coords= ("index": np.arange(N) ))
```

xarray.Dataset

» Dimensions: (index: 100)

▼ Coordinates:

index	(index)	int64	0	1	2	3	4	5	6	...	94	95	96	97	98	99
-------	---------	-------	---	---	---	---	---	---	---	-----	----	----	----	----	----	----

▼ Data variables:

h0	(index)	float64	5.73	9.176	8.887	...	8.64	11.1
h1	(index)	float64	9.859	14.38	15.54	...	13.77	15.13
treatment	(index)	int64	0	0	0	0	0	0
fungus	(index)	int64	0	0	0	0	1	0

2.) atj je tipiskā rast rastlīn?

$h_1 \sim \text{Normal}(\mu_i, \sigma)$

$\mu_i = h0_i \cdot \rho$

↳ Finālā vājšķu = pōi.vājšķu

$h_1 \sim \text{Normal}(\mu, \sigma)$
 $\mu = h_0 \cdot \rho$
 $\rho = \text{CorrNormal}(1, 0.2)$

2.) fit. model

$$h_1 = \rho \cdot h_0 + \text{chylm}$$

fin.vājšķu je nāsobok pōi.vājšķu

↳ atj je tipiskā rast rastlīn

$$h_{1,i} \sim \text{Normal}(\mu_i, \sigma)$$

$$\mu_i = h_{0,i} \cdot p$$

$$p \sim \text{Log-Normal}(1.0, 0.25)$$

predpoklad z dat je, ze p bude medzi 0.57 az 1.57

	mean	sd	hdi_3%	hdi_97%
x	1.03	0.26	0.57	1.51

FIT MODEL

h1 je vacsinou 1.4x nasobok h0 (pociatocnej) -> 40perct growth on average
a aj 1.36-1.43 spread je super

	mean	sd	hdi_3%	hdi_97%
p	1.40	0.02	1.36	1.43
sigma	2.01	0.15	1.75	2.29

Model2: with treatment(T) and fungus(F) measurements

$$h_{1,i} \sim \text{Normal}(\mu_i, \sigma)$$

$$\mu_i = h_{0,i} p$$

$$p = \alpha + \beta_T T_i + \beta_F F_i$$

$$\alpha \sim \text{Log-Normal}(0, 0.25)$$

$$\beta_T \sim \text{Normal}(0, 0.5)$$

$$\beta_F \sim \text{Normal}(0, 0.5)$$

$$\sigma \sim \text{Exponential}(1)$$

```
with pm.Model() as m_6_7:
    a = pm.Normal("a", 0, 0.2)
    bt = pm.Normal("bt", 0, 0.5)
    bf = pm.Normal("bf", 0, 0.5)

    p = a + bt * d.treatment.values + bf * d.fungus.values

    mu = p * d.h0.values
    sigma = pm.Exponential("sigma", 1)


    h1 = pm.Normal("h1", mu=mu, sigma=sigma, observed=d.h1.values)

    m_6_7_idata = pm.sample(random_seed = rng)
```

	mean	sd	hdi_3%	hdi_97%
a	1.49	0.03	1.44	1.53
bt	0.01	0.03	-0.04	0.07
bf	-0.30	0.03	-0.36	-0.24
sigma	1.32	0.10	1.14	1.49

Vyzera to tak, ze treatement nema vplyv na growth. ALE TO JE BLBOST.
Iba F (-0.30) ma.

PRECO ? PRECO TO TAK JE ?



T a H1 su d-separated podmienenim na F.
Teda ak pozname F, tak T nam uz nic nove o H1 nepovie.

Ked podmienime na F, tak cestu T-H1 zablokujeme.


A NASTAVA POST-TREATEMENT BIAS.
Ak pridam F do regresie, odstranjujeme efekt T.

ak vieme F (plesen) tak T nam uz heda ziadnu additional info.
ak vieme F (plesen) tak T uz nema ziadny vplyv na H1.

Ak chceme merat efekt T na H1, nemozeme dat F do regresie, pretorze F je vysledkom T.

Collider BIAS: chyba ktorá vznikne keď kontrolujeme var,


M: moisture



Ak kontrolujeme F, ktoré je výsledkom T aj M, vytvoríme falošný efekt T na H1, aj keď T v skutočnosti nič nerobí.

DALŠÍ PŘÍKLAD


T: tratenem
N: Noise
S: selected



T ovplyvňuje, či sa niečo vyberie (S).
N ovplyvňuje, či sa niečo vyberie (S).

S je výsledkom 2 vecí naraz.
To je COLLIDER

Keď podmienime na S, tak vznikne vzťah medzi T a N, hoci normálne nieje.



example

Príklad reštaurácie (good food vs good location)

Predstav si:

- Kvalita jedla (F)
- Lokalita (L)
- Prežitie reštaurácie (S)

Platí:

Dobré jedlo → vyššia šanca prežiť
Dobrá lokalita → vyššia šanca prežiť

Ale medzi kvalitou jedla a lokalitou nemusí byť žiadny vzťah.

Teraz spravíme chybu

Pozrieme sa len na reštaurácie, ktoré prežili (S).

Zrazu uvidíme:

Medzi preživšími platí:

- ak nemá dobrú lokalitu, musí mať veľmi dobré jedlo
- ak má slabé jedlo, musí mať top lokalitu

Vznikne negatívna korelácia.

Nie preto, že existuje.
Ale preto, že sme podmienili na „prežitie“.

To je collider bias.

example

Another Simulated Experiment (Time Permitting)

- (1) Each year, 20 people are born with uniformly distributed happiness values.
- (2) Each year, each person ages one year. Happiness does not change.
- (3) At age 18, individuals can become married. The odds of marriage each year are proportional to an individual's happiness.
- (4) Once married, an individual remains married.
- (5) After age 65, individuals leave the sample. (They move to Spain.)

- The model embeds this collider (do we agree?)

H → M ← A

H = happiness


A = age

M = married

Simulate model for 1000 years

	mean	sd	hdi_3%	hdi_97%
age	32.00	18.77	0.0	61.00
happiness	-0.00	1.21	-2.0	1.79
married	0.28	0.45	0.0	1.00

- People are roughly as happy as unhappy in the population (as we simulated)
- A bit less than 30% are married on average



Ak do model name M (married), dostaneme ze H a A su negative korelované.

Ale v geneovani dat bolo H nahodne, nikde sme nedali H->A alebo A->H.... takže korelaci je cisto artefakt vyberu.

Collider bias môže vzniknúť:

- aj keď collider nezmeriame
- aj keď ho nedáme do regresie

Stačí, že dáta sú už vybrané podľa neho.

5 „We often get data already conditioned“

Toto je survivorship bias.

Príklady:

- študujeme len úspešné firmy
- študujeme len prijaté granty
- študujeme len ženatých
- študujeme len pacientov, čo prežili


Dáta sú už filtrované cez collider.

A my si to často ani neuvedomíme.

Collider bias:

- 👉 vytvára závislosť medzi dvoma príčinami,
- 👉 keď podmienime na ich spoločný následok.

Summary of Confounder Patterns



Z je spoločná príčina X a Y.

Bez podmienenia:


X a Y budú korelované (cez Z).

Ak podmienime na Z:

$X \perp Y | Z$

Cesta sa zablokuje.

👉 Z treba zahrnúť do modelu.



Z je medzičlánok (mechanizmus).

Bez podmienenia:

X ovplyvňuje Y.


Ak podmienime na Z:

Zablokujeme kauzálnu cestu.

$X \perp Y | Z$

👉 Ak chceme celkový efekt X na Y, Z NESMIEME kontrolovať.

Toto bol fungus príklad ($T \rightarrow F \rightarrow H1$).



Z má dve príčiny.

Bez podmienenia:

$X \perp Y$


Ak podmienime na Z:

Vznikne závislosť.

$X \not\perp Y | Z$

👉 Z nesmieme kontrolovať.

Toto bol marriage príklad.



D je potomok collidera.

Ak podmienime na D, je to ako keby sme podmienili na Z.

👉 Tiež vytvoríme falošnú závislosť.

Pattern	Kontrolovať Z?	Prečo
Fork	ÁNO	blokujeme confounder
Pipe	NIE (ak chceme total effect)	blokujeme mechanizmus
Collider	NIE	vytvoríme fake koreláciu
Descendant	NIE	rovnaké ako collider

A procedure to address these 4 confounds, assuming you have a complete DAG

DAG = nakreslit si ten diagram závislosti

Chces odhadnut efekt $X \rightarrow Y$
 Question: co mam kontrolovat v regresii?


(najprv dag)
 1.) Najdi vsetky cesty medzi X a Y (nie len priamu ale vsetky mozne)
 napr.

- $X \rightarrow Y$
- $X \leftarrow Z \rightarrow Y$
- $X \rightarrow Z \rightarrow Y$
- $X \rightarrow Z \leftarrow Y$

2.) Oznacis ktore su BACKDOOR (cesta, kde sipka ide DO X)
 3.) Pozris ci cesta je otvorena alebo zatvorena

Pattern	Cesta je otvorená?
Fork	áno
Pipe	áno
Collider	nie
Descendant of collider	pozor

4.) Zatvoris vsetky backdoor cesty.
 napr. ak je cesta. $X \leftarrow Z \rightarrow Y$ to je fork....
 musis kontrolovat Z



Chceme efekt $X \rightarrow Y$

1.) Vzťahy:

- $U \rightarrow X$
- $X \rightarrow Y$
- $C \rightarrow Y$
- $A \rightarrow U$
- $A \rightarrow C$
- $U \rightarrow B$
- $C \rightarrow B$

Nemôžeme merať U.
Môžeme merať A, B, C.

2.) Najdi všetky cesty medzi X a Y

Cesta 1:

$X \leftarrow U \leftarrow A \rightarrow C \rightarrow Y$

Cesta 2:

$X \leftarrow U \rightarrow B \leftarrow C \rightarrow Y$

Obe začínajú šípkou do X.

👉 Obe sú **backdoor**.

3.) Su otvorene?

Path (1):

$X \leftarrow U \leftarrow A \rightarrow C \rightarrow Y$

Žiadny collider.

👉 Je otvorená.

👉 Robí confounding.

Path (2):

$X \leftarrow U \rightarrow \underline{B} \leftarrow C \rightarrow Y$

B má dve šípky dovnútra:

$U \rightarrow B \leftarrow C$

👉 B je collider. ✓

👉 Táto cesta je prirodzene zatvorená.

Takže path (2) nás zatiaľ netrápi.


4.) Co musime zatvoriť?

$X \leftarrow U \leftarrow A \rightarrow C \rightarrow Y$

Ako?

Stačí podmieniť na A alebo C.

Obe ležia na tejto ceste.



⚠️ **Ale pozor**

Nesmieš podmieniť na B.

Prečo?

Lebo B je collider.

Ak by si kontroloval B:

$X \leftarrow U \rightarrow B \leftarrow C \rightarrow Y$

Sa otvorí.

A vytvoríš nový problém.

🚦 Takže čo máme spraviť?

Možnosti:

- Kontrolovať A
- Kontrolovať C

Text hovorí:

👉 C je lepšia voľba
(pretože je bližšie k Y, a blokuje silnejší efekt)

🔑 Najdôležitejšie pochopenie

- B je collider → nikdy ho nekontroluj
- A alebo C sú na backdoor ceste → musíme kontrolovať aspoň jeden