

1.) Under fitting / over-fitting

• UNDER FITTING: model je príliš jednoduchý $\Rightarrow$ nemôže zhrnúť dáta
vysoká chyba na test, train $\Rightarrow$ vysoký bias

• OVERFITTING: model je príliš komplexný $\Rightarrow$ naučí sa $\bar{S}UM$, high variance
nízka chyba na train, vysoká na test

2.) Information theory o presnosti predikcie

predikcia = redukcia neistoty

Entropy = miera neistoty

Lepsi model $\rightarrow$ nižšia cross-entropy / log loss

AKAIKEHO PRINCÍP $\Rightarrow$ model má maximalizovať out-of-sample likelihood, NIE FIT
NA TRAIN

3.) REGULARIZATION (abr brzdí overfitting)

- L2 (Ridge) $\rightarrow$ znižuje váhy
- L1 (Lasso) $\rightarrow$ Robí sekvenciu premenných
- elastic net $\rightarrow$ kombinácia

optimalizujeme $\boxed{\text{Loss} + \lambda \cdot \text{penalty}}$ λ = riadi bias-variance trade off

4.) odhad presnosti predikcie

- CV (Cross-validation) - robustný odhad out-of-sample error
- PSIS-LOO (efektívna aproximácia leave-one-out)
- WAIC $\rightarrow$ bayesian information criterion

$\rightarrow$ odhadnúť generalizačnú schopnosť modelu

5.) Presnosť / kauzalita

model môže mať vysokú presnosť BEZ toho aby poskytol kauzálne
Korelácia $\neq$ kauzalita ostatné

Robust regression - znižuje vplyv outlierov, nie je to kauzálna metóda

1) OVER / UNDER FITTING

linear regression: $x = \text{body mass}$
 $y = \text{brain volume}$

assumptions: $\alpha \sim N(\mu=0.5, \sigma=1)$
 $\beta \sim N(\mu=0, \sigma=10)$

brain_i ~ $N(\mu_i, \sigma)$

bayesian regression


$$w_i = \alpha + \beta \cdot \text{mass_std}_i$$

	mean	sd	hdi_3%	hdi_97%
α	0.527	0.111	0.318	0.731
$\beta[0]$	0.166	0.122	-0.060	0.389
$\log_\sigma$	-1.392	0.383	-2.071	-0.679

→ sklon môže byť / \ — napíšu

Let's recreate the posterior plot, just for the first model (for reference purposes, we do not need to discuss this in class).







```
az.plot_posterior(idata_7[1].posterior, ...)
```



→ Pravdepodobnejšie pozitívny sklon môže byť aj — alebo klesajúci

⇓
 dáta neposkytujú silný signál o lineárnom vzťahu

⇓
 Skúsme viac polynómov



abr
sistit
ci nemame mpr.
v oversitting?

MEASURING OVER/UNDER USING information theory

- Which of the above models is best?
- Ideally: not the one closest to the sample but the one closest to the (unknown) distribution from which the sample is drawn
- Need: some notion of closeness (distance) of distributions
- Answer: use information theory

Entropy: meria neistnot.
↳ chceme model kt. minimalizuje

$$-\log p(y_{\text{true}} | \text{model})$$

↓
log -loss alebo log predictive density

↓
čím vyššia pravdepodobnosť, tým model priťahuje
skutočným dátam ⇒ tým menej vhodný
↓
lepší model

$m_{7-1} \rightarrow$ under fit

$m_{7-7} \rightarrow$ over fit

ale ako by to bolo?

↓

rozšíť $\rightarrow$ LOO (leave 1 out)

$\rightarrow$ WMAE

$$\sum \log p(y_i | y_{-i}) \rightarrow$$

model s najnižšou ELPD vyhráva.

$$H(p) = - \sum p_i \log p_i$$

meria nultomú nultku jedrej distribúcie

príklad $[0.5, 0.5] \rightarrow$ maximálna nultka

$[0.3, 0.5] \rightarrow$ menšia nultka

How HARD IS DISTRIBUTION TO PREDICT.

KL divergencia $\rightarrow$ ak $q=p \rightarrow KL=0$

čím viac sa q líši od p , tým väčšia divergencia

Ak model priade mádu pravdepodobnosť skutočným dátam

divergence
explodes

↓

informácia stráca,

keď používame model q namiesto p .

p = skutočný generujúci proces $\rightarrow$ **Nepoznáme ho**
 q = každý z našich modelov.

best je ten, kto MINIMALIZUJE

$D_{KL}(p \parallel q)$ ale p nepoznáme

tak ho

APPROXIMUJE

LOO
OWALC
ELPD

Prečo OVER FITTING PRETRÉNIVO?

Lo príde extrémne vysokú pravdepodobnosť tréningovým bodom
 ale nízku pravdepodobnosť iným množinám dát.

ak Loo (mediana jeden bod var, model ho predikuje ZLE
 log-prot je nízka
 KL rastie

Prečo UNDER FITTING PRETRÉNIVO:

nízky meda vysokú pravdepodobnosť skutočným dátam

↓
 vysokej KL

ex: H paha v 30%. ale to je $p=0.3$ ale to variace

skitsano model:

$H1: 0.3$

$H2: 0.5$


$H3: 0.9$

Graf.

X = číslo kt. model vidí (0-1)

Y = číslo kt. hovorí ako veľmi sa ten model nájde oproti realite 0-3

- ak model povie 0.3 $\rightarrow$ dŕha je 0



LOG-POINTWISE - PREDICTIVE - DENSITY (LPPD)

ak estimujeme over/under fitting tak by sme mali vedieť ako dobre sme od target distribution. ale p je unknown

chceme $D_{KL}(p||q)$

ale p (realita) nepoznáme

takže máme vypočítať skutočnú KL divergence

$\downarrow$

nebudeme poznáť p , stačí poznať
sčítavme log - pravdepodobnosť dát

$$LPPD = \sum \log p(y_i | \text{model})$$

Pre každý bod: - vezmeme pravdepodobnosť kt. model prirodzene
- Zoberieme log
- Spočítame cez všetky body.

Vyššia LPPD = model dáta dáta

Vyššia pravdepodobnosť.

~~je~~ je bližšie k realite
 $\rightarrow$ má menšiu odchýlku

LPPD below approximates just one of the terms in (*) above, so p below stands for r or for q in (*). And when we compare models we need to calculate lppd for each of them.

$$\text{lppd}(y, \Theta) = \sum_i \log \frac{1}{S} \sum_s p(y_i | \Theta_s)$$

where

- p is the model (the posterior density)
- S is the number of samples from posterior
- Θ_s is the s -th set of sampled parameter values.
- i ranges over the ground truth data points (observed data)
- We basically average the terms from the above over the posterior.
- Higher the lppd is better, better match of the posterior with the data

example : ktorý model dáva najvyššiu pravdepodobnosť pozorovaným dátam?

- 1.) Zoberieme 1 dátový bod y_i
- 2.) Spočítame akú pravdepodobnosť mu model dáva
- 3.) Správime to pre celý posterior (všetky Θ v zozb.)
- 4.) Spriemerujeme
- 5.) Zoberieme log
- 6.) Zopakujeme pre všetky body
- 7.) Sčítame

LPPD

ak model vysvetľuje všetky body

↳ bude veľmi vysoká LPPD

Prečo to robíme?

Lebo:

- Skutočné p (realita) nepoznáme
- Nemôžeme spočítať $KL(p||q)$
- Tak porovnávame modely podľa toho, kto lepšie vysvetľuje dáta

To je aproximácia minimalizácie KL divergence.

⚠ Dôležitá vec

Tu sa to ráta na tréningových dátach.

Preto najviac overfitting model vyhrá.

Lebo:

- perfektne prejde cez body
- dá im extrémne vysokú pravdepodobnosť

To je dôvod, prečo treba LOO alebo WAIC.

DEVIANCE → Preškáľovaná LPPD

$$\text{Deviance} = -2 \times \text{LPPD}$$

Ako to interpretovať?

- Nižšia deviance = model dáva vyššiu pravdepodobnosť dátam
- Porovnávajú sa len rozdiely medzi modelmi
- Absolútne číslo nič neznamená

Prečo -?

Historický dôvod zo štatistiky (likelihood ratio testy, AIC, BIC).
Takto sa to štandardne zapisuje.

Ako to interpretovať?

- Nižšia deviance = model dáva vyššiu pravdepodobnosť dátam
- Porovnávajú sa len rozdiely medzi modelmi
- Absolútne číslo nič neznamená

Dôležité


Ak ju rátaš na tréningových dátach:

- Model s viac parametrami vždy vyhrá
- Overfitting

Preto treba LOO / WAIC alebo train/test split.

example: Prečo train score kľame a

Prečo potrebujeme test/cv/LoO



NIEŠŤ
JE
LEPŠIA

Komplexita
modelu

- Note that deviance gets better on the training sample, when the fit is improving (the number of parameters is growing)
- However the deviance on the test samples is growing, from some point so the out-of-sample fit is getting worse
- The figure shows that we can use deviance to see which model fits best (out of the five) but on the **out-of-sample** score.
- Also note the large standard deviation bars: for each individual pair of samples we can say very little - we need simulate many times to make any useful conclusion using means.


Regularizácia: zabrániť modelu robiť extrémne veľké parametre → tým pádom vlníte trvanie (over fitting)

v bayes svete: $\beta \sim N(0, 100)$

$\beta \sim N(0, 100) \rightarrow$ prior je skoro plochý, veľké riziko overfittingu

$\beta \sim N(0, 1)$

veľké hodnoty sú nepravdepodobné
(model bude opatrnejší)




ak redukujem overfitting, tak zvyšujem underfitting.

Regularizácia → ZYŠUJE BIAS,
ZNIŽUJE VARIANCE

Pomôť hlavne ak N je malé

- Of course when you reduce overfitting, you increase the risk of underfitting.
- Also you prior should still only contain prior knowledge, and not be biased in anyway by the data you are seeing.



CROSS-VALIDATION: - rozdeliť dáta na $\begin{cases} \text{train} \\ \text{test} \end{cases}$

- fit model na train
- zmeniť deviance (alebo log-score) na testy
- opakovať viac krát
- Spriemerovať

ex. 10 fold CV


- rozdeliť dáta na 10 častí
- 9 train
- 1 test.
- 10x

L 00 (leave 1 out)

- nedávaš jednu bod rovn
- train na zvyšku
- test na 1 bode
- 10 pre každý bod
- výsledok = priemerový aut → sample log score
- dobry pri 10 fold dátach

WAIC: Widely applicable information criterion
 ↳ sposob ako odhadniti test variance brez toho, da si mal test data

↓
 cross-valid brez razdeljvanja dat



↓ nižje
 lepši

↓ nižje
 lepše

WAIC kopiruje CV/PSIS 😊
 Piste je test výkon

↓
 Použi WAIC/LoO na výber modelu

Correlation is not Causation (Revisited, Section 7.5)

- The best generalizing (best predicting) models can be confounded
- For instance for our fungi-treatment example the best predicting model conditions on the post-treatment effect
- Prediction and Causation are two very different things
- The backdoor paths do carry valid information for prediction, while obscuring causation.
- So you need to understand what kind of model you are building
- The book shows that for the fungi example the confounded model has best prediction metrics.

model kt. najlepšie predikuje, nemusi byť kauzálne správny.

Predoz.


predikcia aka odhadniti (Y)

kauzalita aka pochopiť čo v sebstoye

Robust regression : čo robíš keď máš outliers?

klasik: $y_i \sim N(\mu, \sigma)$

→ extrémny bod má ext. vplyv na parameter



↓ model sa ho snaží prispôbiť

↓ posuní mean

↳ 1 outlier vie pokaziť celý model

→ PRESENIE
Robust




$y_i \sim \text{STUDENT} - A(\eta, \mu, \sigma)$


Student-A má HRUBÉ CHVOSTY

- ext. values majú väčšiu šancu preniknúť.

veľké $N \rightarrow$ skoro N dist.

malé $N \rightarrow$ hrubé chvosty (robust)





→ t-distrib.

→ Šum HDI je manši, lebr manjšuje.

↳ lebr je manjšuje 0
ali zadajtik
vsega OUTLIES