

WEEK 6: Non-linear Interactions in Regression

1. Conditioning Everywhere (8.1)

- každý model je kondicionovaný na niečo
- interakcia = efekt jednej premennej závisí od inej

2. Príklad: Terrain Ruggedness vs GDP

- kategorická interakcia (kontinent mení efekt ruggedness)
- model s indexovanými α a β podľa kontinentu
- prečo nie separate regressions (shrinkage, porovnanie modelov)

3. Symmetry of Interactions (8.2)

- interakcie sú symetrické
- "A mení efekt B" = "B mení efekt A"
- sú descriptive, nie kauzálne

4. Príklad: Tulip Blooms

- kontinuálna interakcia (voda * tieň)
- model: $\mu = \alpha + \beta_W W + \beta_S S + \beta_{WS} W * S$
- bez interakcie: tieň len posúva intercept
- s interakciou: tieň mení silu efektu vody



Bombardéry (dole): Slávny príklad z 2. svetovej vojny. Armáda mapovala zásahy na lietadlách, ktoré sa vrátili z misii. Chceli opancierovať najviac zasiahnuté miesta. Ale Abraham Wald povedal: "Nie — opancierujte miesta, kde zásahy nie sú, pretože lietadlá zasiahnuté tam sa nevrátili."

Spojenie s regresiou a interakciami: To je podstata interakcií — efekt jednej premennej závisí od hodnoty inej premennej (a bola jeho závažnosť). To je podstata interakcií — efekt jednej premennej závisí od hodnoty inej premennej.

Toto je kauzálny graf pre survivorship bias.

$U \rightarrow D \rightarrow S$

- U = nezorovaná premenná (nebezpečnosť)
- D = poškodenie (damage)
- S = prežitie (survival/selection)

Doterajšie modely predpokladali nezávislý aditívny efekt každého prediktora:
 $\mu = \alpha + \beta_1 X_1 + \beta_2 X_2$

Efekt X_1 je vždy rovnaký, bez ohľadu na X_2 .

Problém: V realite efekt jednej premennej často závisí od inej → interakcie.

CONDITIONING EVERYWHERE (Section 8.1)

- Každý štatistický model je kondicionovaný na niečo.
- Lineárna regresia predpokladá nezávislý (univariálny) vplyv každého regresora.
- Interakcia: vplyv jedného prediktora závisí od iného prediktora.
- Interakcia = ďalšie kondicionovanie → parametre závisia od viacerých aspektov dát.
- Interakcie sú "epicykly" v geocentrickom modeli:
 → používať opatrne, len keď underlying reality skutočne také závislosti má.
- Ťažšie na interpretáciu ako čistá lineárna regresia.
- Nie sú priamo viditeľné v kauzálnych grafoch.

PRÍKLAD: Terrain Ruggedness vs Economy

Skúmame vzťah medzi členitosťou terénu (R) a ekonomickou výkonnosťou (G = log GDP, rok 2000).


Kauzálny graf:

- R = členitosť terénu (ruggedness)
- G = GDP
- C = kontinent
- U = nepozorované confoundry

Graf: $R \rightarrow G \leftarrow C$

↑
U

(U ovplyvňuje aj R aj G)





Otázka: Má členitosť terénu iný efekt na GDP v Afrike vs mimo Afriky?

→ To by bola interakcia medzi R a C.

SEPARATE REGRESSION: Afrika vs Zvyšok sveta

Kľúčové zistenie: členitosť terénu má OPAČNÝ efekt podľa kontinentu.

Separate regression for Africa and Outside



- Mimo Afriky: väčšia členitosť → nižší GDP (drahšia doprava, ťažší obchod)
- V Afrike: väčšia členitosť → vyšší GDP (???)

Prečo Afrika inak?

Hypotéza: členitý terén sťažoval kolonizátorom prístup do vnútrozemia

→ menej vykorisťovania → lepší ekonomický štart po nezávislosti

Toto JE interakcia:

Efekt R (ruggedness) na G (GDP) závisí od C (kontinent).

Nemôžeme fitovať jeden model pre všetky krajiny rovnako.

PROBLÉM S DAG-om


DAG ($R \rightarrow G \leftarrow C$) zachytáva len NEZÁVISLÉ vplyvy R a C na G.
Nezachytáva, že tieto vplyvy môžu INTERAGOVAŤ.

Skutočnosť môže byť: $G = f(R, C)$

kde f nie je nutne aditívna funkcia $\beta_1 \cdot R + \beta_2 \cdot C$

Teda efekt R na G môže byť iný pre rôzne hodnoty C

→ to DAG jednoducho neukáže, treba to skúmať štatisticky.



**Záver: DAG nám povie ČO ovplyvňuje ČO,
ale nepovie nám AKO presne (lineárne? interaktívne? inak?)**

PREČO SÚ SEPARATE REGRESSIONS ZLÉ?

1. NIE VŠETKY PARAMETRE ZÁVISIA OD KONTINENTU
 - napr. σ (rozptyl GDP) je rovnaký pre obe skupiny
 - keď dáta rozdelíme, máme menej informácií na odhad týchto parametrov
 - jeden model na všetky dáta = silnejší odhad
2. SEPARATE MODELY NEVEDIA MERAŤ NEISTOTU INTERAKCIE
 - ak chceme vedieť, či kontinent skutočne mení efekt ruggedness, kontinent musí BYŤ v modeli
 - rozdelenie dát = implicitne predpokladáme, že sú to ÚPLNE rôzne situácie (veľmi silný prior) — čo ak to tak nie je?
3. POROVNANIE MODELOV CEZ INFORMATION CRITERIA
 - AIC/WAIC/LOO vyžadujú, aby všetky modely používali rovnaké dáta
 - pri split-e to nie je splnené
4. SHRINKAGE — MODELY SA UČIA NAVZÁJOM
 - v jednom modeli sa kategórie "regularizujú" navzájom
 - pri malom počte krajín v kategórii → riziko overfittingu
 - spoločný model toto riziko znižuje

»

MODEL PRE GDP S INTERAKCIAMI

$\log(y_i) \sim \text{Normal}(\mu_i, \sigma)$

$\mu_i = \alpha_{\text{CID}[i]} + \beta_{\text{CID}[i]} \cdot (r_i - \bar{r})$

$\log(y_i) \sim \text{Normal}(\mu_i, \sigma)$

$\mu_i = \alpha_{\text{CID}[i]} + \beta_{\text{CID}[i]} (r_i - \bar{r})$

Kde:

- $\text{CID}[i]$ = kontinent i-tej krajiny (0 = mimo Afriky, 1 = Afrika)
- $\alpha_{\text{CID}[i]}$ = intercept závisí od kontinentu
- $\beta_{\text{CID}[i]}$ = slope závisí od kontinentu ← TU JE INTERAKCIA
- r_i = ruggedness krajiny, $\bar{r}$ = priemer ruggedness

$\alpha_{\text{CID}[i]} \sim \text{Normal}(1, 0.1)$

$\beta_{\text{CID}[i]} \sim \text{Normal}(0, 0.3)$

$\sigma \sim \text{Exponential}(1)$

Priors:

- $\alpha_{\text{CID}} \sim \text{Normal}(1, 0.1)$ → GDP blízko priemeru (=1 po normalizácii)
- $\beta_{\text{CID}} \sim \text{Normal}(0, 0.3)$ → slope môže byť + aj -
- $\sigma \sim \text{Exponential}(1)$

NORMALIZÁCIA DÁT:

- Ruggedness: 0 až 1
- GDP: vydelené priemerom → priemer = 1 (odchýlka od normy)
- Ruggedness posunutý o priemer ($r_i - \bar{r}$) → lepšia inferencia

Kľúčová myšlienka: α aj β majú INDEX kontinentu

- každý kontinent má svoj vlastný intercept aj slope
- to je interakcia medzi ruggedness a kontinentom

ČOMU SA SNAŽÍME POROZUMIEŤ?
Chceme vedieť: ovplyvňuje členitosť terénu bohatstvo krajiny?

JEDNODUCHÝ MODEL (bez interakcie):
 $GDP = \alpha + \beta * ruggedness$
→ jeden priamkový vzťah pre VŠETKY krajiny sveta

ALE Z DÁT VIDÍME PROBLÉM:
- Mimo Afriky: viac hôr → chudobnejšia krajina (β záporné)
- V Afrike: viac hôr → bohatšia krajina (β kladné)
→ jeden model to nedokáže zachytiť!

KOŤ

ČO ROBIEME S DÁTAMI?

1. Načítame CSV súbor (234 krajín, 51 premenných)
2. Vytvoríme log verziu GDP:
 $\log_gdp = \log(gdp_per_capita_2000)$
→ lebo bohatstvo rastie multiplikatívne
3. Vyhodíme krajiny bez GDP dát:
234 → 170 krajín zostane
4. Normalizujeme:
 $\log_gdp_std = \log_gdp / \text{priemer}(\log_gdp)$ → priemer bude 1
 $rugged_std = rugged / \max(rugged)$ → hodnoty 0 až 1
5. Vypočítame priemer rugged_std (na centrovanie neskôr)

REGRESSION MODEL S INTERAKCIAMI (stavanie statistického modelu)

PREČO $shape=2$? → chceme samostatný parameter pre každý kontinent
 $a \sim \text{Normal}(1, 0.1)$, $shape=2$ → 2 intercepty (priemerné GDP)
 $b \sim \text{Normal}(0, 0.3)$, $shape=2$ → 2 slopes (efekt ruggedness)

PREČO centrujeme R?
 $R = rugged_std - \text{priemer}$
→ aby intercept 'a' mal zmysel (= GDP pri priemernej členitosti)

INTERAKCIA je tu:
 $\mu = a[CID] + b[CID] * R$
→ CID rozhoduje, KTORÝ intercept a slope sa použije
→ Afrika: $a[0] + b[0]*R$
→ Zvyšok: $a[1] + b[1]*R$

LIKELIHOOD:
 $\log_gdp_std \sim \text{Normal}(\mu, \sigma)$
→ hovoríme: dáta sú normálne rozdelené okolo μ s rozptylom σ

PRETO STAVÍME MODEL S INTERAKCIOU:
 $GDP = \alpha[\text{kontinent}] + \beta[\text{kontinent}] * ruggedness$
→ každý kontinent má svoj vlastný α aj β
→ Afrika má iný sklon priamky ako zvyšok sveta

TO JE CELÁ POINTA:
Interakcia = efekt jednej premennej (ruggedness)
závisí od inej premennej (kontinent)

AKO VYZERAJÚ DÁTA? (jeden riadok = jedna krajina)

index	log_gdp_std	rugged_std	kontinent	...
2	0.93	0.12	Afrika	...
4	1.15	0.05	Európa	...
7	0.78	0.45	Afrika	...
...	...	...	...	...

$\log_gdp_std = 1.0$ znamená presne priemer

$\log_gdp_std = 1.2$ znamená o 20% bohatší ako priemer

```
with pm.Model() as m_8_3:

    # 'categories' will be just equal to two (2) in this case (Africa vs Non-Africa),
    # but the code shows how to do this in general, if there are
    # more discrete values

    categories = np.unique(dd.cont_africa.values).size

    # The shape allows us to make 'a' and 'b' into vectors
    a = pm.Normal("a", 1, 0.1, shape = categories)
    b = pm.Normal("b", 0, 0.3, shape = categories)

    R = pm.Data("R", dd.rugged_std.values - rugged_std_mean)
    CID = pm.Data("CID", dd.cont_africa.values)
    LG = pm.Data("LG", dd.log_gdp_std.values)

    mu = pm.Deterministic("mu", a[CID] + b[CID] * R)

    sigma = pm.Exponential("sigma", lam = 1)

    log_gdp_std = pm.Normal("log_gdp_std", mu = mu, sigma = sigma, observed = LG)
```

SAMPLING

Doteraz sme len DEFINOVALI model (povedali sme ako vyzera).
Teraz ho FITUJEME na dáta - hľadáme hodnoty a, b, sigma.

$pm.sample()$ = spustí MCMC algoritmus
→ prejde tisíce možných kombinácií a, b, sigma
→ zahodí tie čo sa nezhodujú s dátami
→ nechá tie čo dobre vysvetľujú dáta

VÝSLEDOK ($m_8_3_trace$):
Nie jedno číslo, ale DISTRIBÚCIA hodnôt pre každý parameter.
Napríklad:
 $b[0]$ (Afrika slope) ~ väčšinou kladné hodnoty
 $b[1]$ (zvyšok slope) ~ väčšinou záporné hodnoty

PREČO random_seed?
→ MCMC je náhodný algoritmus
→ seed zaručí, že výsledky sú reprodukovateľné
(každý kto spustí kód dostane rovnaké výsledky)

```
with m_8_3:
    m_8_3_trace = pm.sample(random_seed = rng)
```

Progress	Draws	Divergences	Step size	Grad evals	Sampling Speed	Elapsed	I
	1999	0	0.870	3	5053.65 draws/s	0:00:00	(
	1999	0	1.274	3	4852.66 draws/s	0:00:00	(
	1999	0	0.769	3	4397.30 draws/s	0:00:00	(
	1999	0	0.842	7	3888.72 draws/s	0:00:00	(

4.) Posterior analýza:

VÝSLEDKY:

a[0] = 1.05 → priemerné GDP v Afrike (intercept)
a[1] = 0.89 → priemerné GDP mimo Afriky (intercept)
→ Afrika má celkovo nižšie GDP (1.05 vs 0.89... počkaj,
0=Afrika, 1=zvyšok, teda zvyšok má nižší intercept?)
→ áno, lebo GDP je normalizované inak

b[0] = -0.14 → slope pre Afriku (členitosť → nižší GDP)
b[1] = 0.13 → slope mimo Afriky (členitosť → vyšší GDP)

KLÚČOVÝ ZÁVER:

b[0] a b[1] majú OPAČNÉ ZNAMENKA!
→ efekt ruggedness je iný pre každý kontinent
→ toto JE interakcia
→ predchádzajúce lineárne modely toto nedokázali zachytiť

HDI intervaly pre b[1] zahŕňajú 0 (-0.01 až 0.27)
→ trochu neistoty, ale trend je jasný

```
az.summary(m_8_3_trace, kind="stats", round_to=2)
```

	mean	sd	hdi_3%	hdi_97%
a[0]	1.05	0.01	1.03	1.07
a[1]	0.89	0.02	0.86	0.92
b[0]	-0.14	0.06	-0.25	-0.04
b[1]	0.13	0.08	-0.01	0.27
sigma	0.11	0.01	0.10	0.12
...	...	...	...	...
mu[165]	1.04	0.01	1.02	1.06
mu[166]	1.03	0.01	1.00	1.05
mu[167]	0.90	0.02	0.86	0.93
mu[168]	0.87	0.02	0.84	0.90
mu[169]	0.88	0.02	0.85	0.91

175 rows x 4 columns

Porovnanie s jednoduchšími modelmi → len na overenie, že náš model s interakciou je naozaj lepší ako bez nej.

TRI MODELÝ:

m_8_1t → jednoduchá regresia, kontinent ignorovaný
m_8_2 → kontinent mení len intercept (a), nie slope
m_8_3 → kontinent mení aj intercept aj slope (= interakcia)

VÝSLEDKY (LOO cross-validation):

m_8_3: loo = -259 → NAJLEPŠÍ (rank 0)
m_8_2: loo = -252 → d_loo = 6.8
m_8_1t: loo = -188 → d_loo = 70.4 → ďaleko najhorší

PREČO m_8_3 VYHRÁVA?

LOO meria prediktívnu silu na nových dátach.
m_8_3 má najnižšiu deviance → najlepšie predpovede.
→ interakcia skutočne zachytáva niečo reálne v dátach.

ZÁVER:

Nestačí vedieť, že Afrika má iné priemerné GDP (m_8_2).
Treba vedieť, že ruggedness pôsobí v Afrike inak (m_8_3).

PREČO MODEL BEZ INTERAKCIE ZLYHÁVA?

Model m_8_2:

$\mu = \alpha[\text{kontinent}] + \beta * \text{ruggedness}$
→ každý kontinent má iný intercept (α)
→ ALE slope (β) je ROVNAKÝ pre oba kontinenty

VÝSLEDOK (graf):

Obe priamky majú rovnaký sklon → idú paralelne.
Model len posunie priamku hore/dole podľa kontinentu.


PROBLÉM:

Z dát vieme, že Afrika má kladný sklon a zvyšok záporný.
Tento model to nedokáže zachytiť - sklony sú rovnaké!

→ Zachytáva: Afrika má celkovo nižšie GDP (rozdiel intercept)
→ NEzachytáva: ruggedness pôsobí inak v Afrike vs zvyšok

ZÁVER:

Bez interakcie vidíme len "kto je bohatší",
nie "prečo ruggedness pomáha v Afrike a škodí inde".



Plotting model with interactions:


Prečo? Doteraz sme mali len čísla z posterioru.
Teraz vidíme výsledok vizuálne.

Výsledok (2 grafy):

- Mimo Afriky: sklon ZÁPORNÝ → viac hôr = chudobnejšia krajina
- Afrika: sklon KLADNÝ → viac hôr = bohatšia krajina

Šedá plocha = 97% HDI interval (neistota odhadu sklonu)

Sklopy sú VÝRAZNEJŠIE ako pri separate regression:
→ jeden spoločný model sa naučil viac ako dva oddelené modely



Symmetry of Interactions (Section 8.2):

Interakcie sú SYMETRICKÉ (ako korelácie).

Doteraz sme hovorili:

"kontinent mení efekt ruggedness na GDP"

Ale rovnako správne je povedať:

"ruggedness mení efekt kontinentu na GDP"

Obe interpretácie sú matematicky identické!

DÔLEŽITÉ:

Interakcie nie sú kauzálne → sú len descriptive/predictive.

Nevieme povedať čo spôsobuje čo, len že spolu súvisia.

1.) Načítanie a príprava dát - Tulip Blooms

Nový príklad: čo ovplyvňuje veľkosť kvetov tulipánov?

PREMENNÉ:

- bed = záhon (a, b, c) → kategorická
- water = množstvo vody (1, 2, 3) → málo/stredne/veľa
- shade = množstvo tieňa (1, 2, 3) → málo/stredne/veľa
- blooms = veľkosť kvetu → OUTCOME (čo chceme predpovedať)

27 tulipánov celkovo.

NORMALIZÁCIA:

blooms_std = blooms / max(blooms) → hodnoty 0 až 1

water_cent = water - priemer → centrovanie

shade_cent = shade - priemer → centrovanie

PREČO CENTROVANIE?

→ intercept bude mať zmysel (= veľkosť kvetu pri priemernej vode a tieni)

→ ľahšie priors

DÁTA (jeden riadok = jeden tulipán):

index	bed	water	shade	blooms	blooms_std	water_cent	shade_cent
0	a	1	2	0.0	0.00	-1	0
1	a	1	1	0.0	0.00	-1	-1
2	a	2	3	111.0	0.36	0	1
3	b	2	1	304.5	1.00	0	-1
...	...	...	...	...	...	...	...

water_cent: 1→-1, 2→0, 3→1 (odčítali sme priemer=2)

shade_cent: rovnako

blooms_std=1.0 → najväčší kvet v datasete

blooms_std=0.0 → žiadny kvet

2.) Model pre veľkosť kvetov:

OTÁZKA: Čo ovplyvňuje veľkosť tulipána?
 - voda (W) a tieň (S) - ale NIE nezávisle!
 - veľa vody + žiadne slnko → kvet nerastie
 - veľa slnka + žiadna voda → kvet nerastie
 - oboje spolu → kvet rastie dobre
 → voda a tieň INTERAGUJÚ

MODEL:

$B_i \sim \text{Normal}(\mu_i, \sigma)$

$\mu_i = \alpha + \beta_W W_i + \beta_S S_i + \beta_{WS} S_i W_i$

Kde:

α = intercept (základná veľkosť)

β_W = efekt vody

β_S = efekt tieňa

β_{WS} = interakčný term (S^*W) ← NOVÉ

DÔLEŽITÉ:

β_{WS} nemá ľahko interpretovateľný význam sám o sebe.

Je to "epicycle" → nie je prirodzený ani vysvetliteľný,
 ale môže zlepšiť predikcie.

ROZDIEL OD PREDOŠLÉHO PŘÍKLADU (GDP):

Tu neindexujeme cez kategóriu (CID),

ale priamo násobíme dve spojité premenné: S^*W

3.) Model BEZ interakcie (m_8_4) + Sampling:

Prečo najprv bez interakcie?

→ Baseline model - chceme vedieť ako dobre funguje
 jednoduchý model pred tým, ako pridáme interakciu.


→ Potom porovnáme s modelom s interakciou.

Výsledok samplingu: 0 divergencií → sampling prebehol dobre.

```
with pm.Model() as m_8_4:
    a = pm.Normal("a", 0.5, 0.25)
    bw = pm.Normal("bw", 0, 0.25)
    bs = pm.Normal("bs", 0, 0.25)
    sigma = pm.Exponential("sigma", 1)

    mu = pm.Deterministic("mu", a + bw * d.water_cent.values + bs * d.shade_cent.values)
    blooms_std = pm.Normal("blooms_std", mu, sigma, observed = d.blooms_std.values)

    m_8_4_trace = pm.sample(3000, random_seed = rng)
```



4.) Model S interakciou (m_8_5) + Sampling:

Oproti predošlému modelu pridáme len jeden nový parameter:

$bws = \text{interakcia vody a tieňa } (W * S)$

$\mu = a + bw^*W + bs^*S + bws^*W^*S$ ← interakčný term

Výsledok samplingu: 0 divergencií → sampling prebehol dobre.


Teraz máme dva modely (m_8_4 a m_8_5) a porovnáme ich.

```
with pm.Model() as m_8_5:
    a = pm.Normal("a", 0.5, 0.25)
    bw = pm.Normal("bw", 0, 0.25)
    bs = pm.Normal("bs", 0, 0.25)
    bws = pm.Normal("bws", 0, 0.25)
    sigma = pm.Exponential("sigma", 1)

    mu = pm.Deterministic("mu",
        a + bw * d.water_cent.values +
        bs * d.shade_cent.values +
        bws * d.water_cent.values * d.shade_cent.values)
    sigma = pm.Exponential("sigma", 1)

    blooms_std = pm.Normal("blooms_std", mu, sigma, observed = d.blooms_std.values)

    m_8_5_trace = pm.sample(random_seed = rng)
```




5.) Vizualizácia: triptych (3x2 grafy)

ŠTRUKTÚRA:

- 3 stĺpce = 3 úrovne tieňa (shade = -1, 0, +1)
- 2 riadky = model bez interakcie (m8.4) vs s interakciou (m8.5)
- každý graf: 20 línií z posterioru (neistota)


Horný riadok (bez interakcie, m8.4):

- sklony línií sú rovnaké vo všetkých 3 grafoch
- tieň len posúva priamky hore/dole (zmena interceptu)
- model "nevie" že tieň mení efekt vody



Dolný riadok (s interakciou, m8.5):

- shade=-1 (málo tieňa): voda má SILNÝ efekt → strmé línie
- shade=0 (stredne): voda má stredný efekt
- shade=+1 (veľa tieňa): voda má takmer NULOVÝ efekt → ploché línie



ZÁVER:

Interakcia zachytáva realitu:

"Keď je príliš veľa tieňa, voda tulipánu nepomôže."

Bez interakcie to model jednoducho nevidí.