

Big Entropy and GLM - agenda:

1. Maximum Entropy Distributions
 - prečo používame určité distribúcie (Normal, Binomial...)?
 - odpoveď: lebo majú najväčšiu entropiu za daných podmienok
2. Generalized Linear Model (GLM)
 - čo sú link functions a prečo ich potrebujeme?
 - ako rozšíriť lineárnu regresiu na rôzne typy outcome-ov
3. Summary regresii
 - prehľad všetkého čo sme sa naučili

Maximum Entropy Distributions:

HLAVNÁ MYŠLIENKA:

Vyber distribúciu ktorá je čo najširšia a najmenej informatívna, ale stále spĺňa to čo vieš o dátach.

PREČO?

- nepridávaš žiadne informácie navyše ktoré nemáš
- žiadny arbitrary bias v modeli
- nechávaš dáta hovoriť samé za seba

V PRAXI:

Maximum entropy likelihood = najmenej biased odhad parametrov
Maximum entropy prior = najmenej biased prior

DOBRÁ SPRÁVA:

Netreba sa učiť nové exotické distribúcie!

Maximum entropy distribúcie sú tie ktoré už poznáme:

- Normálna, Binomická, Poissonova...
- každá je maximum entropy pre určitý typ dát/podmienok

PRÍRODA:

Empirické distribúcie v prírode majú vysokú entropiu

- preto tieto distribúcie fungujú tak dobre v praxi

Definícia entropie:

VZOREC (diskrétny prípad):

$$H(p) = -\sum_i p_i \log(p_i)$$

$$H(p) = -\int p(x) \log p(x) dx$$

Kde p_i = pravdepodobnosť každého výsledku

PRÍKLAD - férová minca (50/50):

$$H = -(0.5 \cdot \log(0.5) + 0.5 \cdot \log(0.5)) = 0.693 \rightarrow \text{vysoká entropia}$$

PRÍKLAD - nakladaná minca (99/1):

$$H = -(0.99 \cdot \log(0.99) + 0.01 \cdot \log(0.01)) = 0.056 \rightarrow \text{nízka entropia}$$

MAXIMUM ENTROPY DISTRIBÚCIA:

Distribúcia ktorá:

1. Spĺňa naše podmienky (napr. known mean, variance)
2. Má najväčšiu entropiu spomedzi všetkých takých distribúcií

= distribúcia ktorá predpokladá čo najmenej navyše

Entropia = miera neistoty / nepredvídateľnosti

JEDNODUCHÝ PRÍKLAD:

Minca: hlava alebo písmo (50/50)

→ vysoká entropia = nevieš čo padne

Nakladaná minca: hlava 99%, písmo 1%

→ nízka entropia = takmer vždy vieš čo padne

INTUÍCIA:

Vysoká entropia = veľa prekvapení = veľa informácie

Nízka entropia = málo prekvapení = málo informácie

PREČO NÁS TO ZAUJÍMA?

Maximum Entropy princíp hovorí:

"Vyber distribúciu ktorá má najväčšiu entropiu a zároveň spĺňa to čo vieš o dátach"

= "Predpokladaj čo najmenej, len to čo vieš"

= konzervatívny, férový prior

Príklad: ak vieš len priemer dát → použij Normálnu distribúciu
lebo má najväčšiu entropiu spomedzi distribúcií s daným priemerom.

PRÍKLAD - prečo uniform distribúcia má najväčšiu entropiu:

SITUÁCIA:

5 vedierok, 10 kameňov náhodne hodených do vedierok.

DISTRIBÚCIE A-E (koľko spôsobmi môžu nastať):

A: všetky kamienky v jednom vedierku → 1 spôsob (najmenej pravdepodobná)

B: 8 v jednom, po 1 v dvoch → 90 spôsobov

C: 6 v jednom, po 2 v dvoch → 1 260 spôsobov

D: rozdelené nerovnomerne → 37 800 spôsobov

E: po 2 v každom vedierku → 113 400 spôsobov (najviac!)

ZÁVER:


Uniform distribúcia (E) sa môže realizovať
v NAJVIAC spôsoboch → má najväčšiu entropiu.

INTUÍCIA:

**Distribúcia s najväčšou entropiou = tá ktorá
nepredpokladá nič navyše (prečo by bolo jedno
vedierko špeciálnejšie ako iné?)**

Graf vpravo dole potvrdzuje:

viac spôsobov → vyššia entropia (priamkový vzťah)



Wallis Derivation:

CIEĽ:

Matematicky dokázať že distribúcia ktorá nastane
v najviac spôsoboch = maximum entropy distribúcia.

Teda: experimentálny výsledok z predošlého príkladu
je teraz dokázaný matematicky.

PREDPOKLADY:

- M vedierok, N kameňov (N je veľké)
- každý kamienok padne do ľubovoľného vedierka rovnako
- $p_i = n_i/N$ = podiel kameňov v i-tom vedierku
- opakujeme mnohokrát → vyberieme najčastejšiu distribúciu

Toto je len formálny základ pre dôkaz.

Nepotrebujeme vedieť dôkaz naspamäť,

len pochopiť záver:

**maximum entropy = distribúcia ktorá môže nastať najviac
spôsobmi**

= distribúcia ktorá predpokladá najmenej navyše.

WALLIS PROOF - čo sa deje (bez matematiky):

ŠTART:

Koľko spôsobmi môžeme rozdeliť kamienky do vedierok? → W

CIEĽ:

Nájsť rozdelenie ($p_1, p_2, \dots$) ktoré maximalizuje W.

TRIK:

Namiesto W maximalizujeme $\log(W)/N$

→ rovnaký výsledok (log je monotónny)

→ ale matematicky jednoduchšie

STIRLINGOVA APROXIMÁCIA:

Pre veľké N: $\log(N!) \approx N \cdot \log(N) - N$

→ dosadíme a zjednodušíme...

ZÁVER (po zjednodušení):

$\log(W)/N = -\sum p_i \cdot \log(p_i) = H(p)$

⚡ **TOTO JE KLÚČOVÉ** ⚡

Maximalizovať W = maximalizovať entropiu $H(p)$

TEDA:

Distribúcia ktorá nastane v najviac spôsoboch

= distribúcia s najväčšou entropiou

= maximum entropy distribúcia ✓

Dôkaz hotový 🤖

BAYES THEOREM A MAXIMUM ENTROPY:

PREDTÝM (Wallis):

Kamienky padajú rovnako do každého vedierka (uniform)
→ posterior = maximum entropy distribúcia

TERAZ (zovšeobecnenie):

Kamienky nepadajú rovnako → máme prior q_i
→ posterior nie je uniform maximum entropy
→ ale stále je "čo najbližšie k prioru"

KL DIVERGENCIA:

Meria ako veľmi sa dve distribúcie líšia.

$$KL(p, q) = \sum p_i \cdot \log(p_i/q_i)$$

ZÁVER:

Bayesov theorem vracia posterior ktorý:

1. Je konzistentný s dátami (splňa constraints)
2. Je čo najpodobnejší prioru (minimálna KL divergencia)

JEDNODUCHO:

Posterior = "update prioru čo najmenej"

→ len toľko zmeny koľko dáta vyžadujú

→ žiadna extra informácia navyše

GAUSSOVA (NORMÁLNA) DISTRIBÚCIA - prečo ju používame:

ODPOVEĎ:


Normálna distribúcia = maximum entropy distribúcia
ak poznáme mean a variance.

INTUÍCIA:


Plochšia distribúcia = vyššia entropia (viac neistoty)

Ale variance musí zostať fixná → nemôžeme ju robiť donekonečna plochou

→ Normálna distribúcia je najplochšia distribúcia
ktorá má danú variance ✓



Ľavý: Normálna (modrá) vs iné distribúcie s rovnakou variance
→ Normálna je najplochšia



Pravý: entropia vs shape parameter
→ maximum pri shape=2 = Normálna distribúcia ✓

PROOF - záver (jednoducho):

CIEĽ: dokázať že Normálna distribúcia má najväčšiu entropiu

NÁSTROJE KTORÉ POUŽIJEME:

1. Entropia $H(p)$:

Miera neistoty distribúcie (už vieme)

2. Cross-entropia $H(q,p)$:

Meria ako dobre distribúcia p opisuje distribúciu q
= entropia q cez "okuliare" p

3. KL divergencia $D(q,p)$:

Meria vzdialenosť medzi dvoma distribúciami

VŽDY ≥ 0 (dve distribúcie nemôžu byť "záporné ďaleko")
= 0 len ak sú identické

POSTUP:

KL divergencia = $-H(q) - H(q,p) \geq 0$

→ teda $H(q,p) \geq H(q)$... (toto je vždy pravda)

Keď dosadíme p = Normálna:

$H(q,p) = -H(p)$... (vypočítali sme matematicky)

Teda:

$-H(p) \geq H(q)$

→ $H(p) \geq H(q)$ ✓

ZÁVER:

Normálna distribúcia p má väčšiu entropiu
ako akákoľvek iná distribúcia q s rovnakou variance.

QED 😊

ZÁVER:

Nepoužívame Normálnu distribúciu len zo zvyku.

Používame ju lebo za podmienky "known mean and variance"
predpokladá čo najmenej navyše = maximum entropy.

BINOMICKÁ DISTRIBÚCIA - prečo ju používame:

ČO JE TO?

Počet úspechov v n nezávislých pokusoch
kde každý pokus má pravdepodobnosť úspechu p.

Príklad: 20 hodov mincou, koľko padne hláv?

PREČO JE TO MAXIMUM ENTROPY?

Binomická = maximum entropy distribúcia ak:
1. Len dva možné výsledky (úspech/neúspech)
2. Poznáme očakávaný počet úspechov (p)

= predpokladáme čo najmenej za týchto podmienok

SPOJENIE S PREDOŠLÝM:

Normálna = maxent ak poznáme mean a variance

Binomická = maxent ak poznáme len p (dva výsledky)

ZÁVER:

Keď máš binárny outcome (áno/nie, 0/1)

a poznáš len pravdepodobnosť úspechu

→ použi Binomickú distribúciu

→ lebo predpokladáš čo najmenej

BINOMICKÁ = MAXENT aj pre $p \neq 0.5$:

PRÍKLAD: $np = 1.4$ (expected 1.4 úspechu z 2 pokusov)

GRAFY:

Ľavý: distribúcia entropií náhodných distribúcií
→ A má najvyššiu entropiu spomedzi všetkých

Pravý: ako vyzerajú distribúcie A,B,C,D:
A (Binomická): relatívne rovnomerná → vysoká entropia ✓
B,C,D: čoraz nerovnomernejšie → nižšia entropia

ZÁVER:

Binomická distribúcia = maximum entropy
pre AKÚKOLVEK hodnotu p (nielen 0.5)

→ podmienka: len 2 výsledky + known expected value

Teda: kedykoľvek máš binárny outcome

→ Binomická je správna voľba

→ predpokladáš čo najmenej

PRÍKLAD - guľôčky a maximum entropy:

SITUÁCIA:

2 biele, 2 čierne guľôčky, vyberáme 2 s vrátením.

Možné výsledky: ww, bw, wb, bb

OTÁZKA: Ktorá distribúcia je najmenej biased?

4 rôzne distribúcie (A,B,C,D) - všetky majú rovnaký expected value (1 modrá z 2 ťahov)

ENTROPIA KAŽDEJ:

A: 1.3862 ← NAJVYŠŠIA → maximum entropy ✓

B: 1.3296

C: 1.3296

D: 1.2130 ← najnižšia

KTORÁ JE A?

Uniform distribúcia → každý výsledok rovnako pravdepodobný
(ww=25%, bw=25%, wb=25%, bb=25%)



ZÁVER:

Ak vieš len expected value ($p=0.5$)

→ uniform distribúcia predpokladá čo najmenej

→ má najvyššiu entropiu

→ = Binomická distribúcia v tomto prípade ✓



PROOF - Binomická je Maxent (záver bez detailov):

ROVNAKÝ TRIK AKO PRI NORMÁLNEJ:

1. Vezmi KL divergenciu (vždy ≥ 0):

$$-H(q,p) \geq H(q)$$

2. Vypočítaj $H(q,p)$ kde p = Binomická:

→ po dosadení a zjednodušení dostaneme $H(p)$

3. Teda:

$$H(p) = -H(q,p) \geq H(q) \quad \checkmark$$

ZÁVER:

Binomická distribúcia p má väčšiu entropiu

ako akákoľvek iná distribúcia q

s rovnakým expected number of successes.

QED 😊

PATTERN ktorý si treba zapamätať:

Normálna = maxent pre known mean + variance

Binomická = maxent pre known p (binary outcomes)

→ oba dôkazy používajú rovnaký trik cez KL divergenciu

GENERALIZED LINEAR MODEL (GLM) - súhrn:

ČO JE TO?

Rozšírenie lineárnej regresie pre rôzne typy outcome-ov.

PREČO?

Lineárna regresia predpokladá Normálny outcome a neobmedzený výsledok ($-\infty$ až $+\infty$).

Ale v praxi máme:

- pravdepodobnosti (0 až 1)
- počty (0, 1, 2, 3...)
- binárne výsledky (0 alebo 1)

Tieto nemôžeme modelovať priamo lineárne.

AKO FUNGUJE GLM?

3 komponenty:

1. Likelihood: vyber správnu distribúciu pre outcome (Binomická pre 0/1, Poissonova pre počty, atď.)
2. Link function f: transformuje parameter distribúcie do neobmedzeného priestoru kde môže pracovať lineárny model
3. Lineárny model: $\alpha + \beta^*x$ (rovnaký ako vždy)

PRÍKLAD:

Normálna regresia: $y_i \sim \text{Normal}(\mu_i, \sigma)$, $\mu_i = \alpha + \beta^*x$

Logistická regresia: $y_i \sim \text{Binomial}(n, p_i)$, $f(p_i) = \alpha + \beta^*x$

ZÁVER:

GLM = správna likelihood + link function + lineárny model

→ umožňuje modelovať takmer akýkoľvek typ dát

Generalized Linear Model (GLM):

DOTERAZ (lineárna regresia):

$y_i \sim \text{Normal}(\mu_i, \sigma)$

$\mu_i = \alpha + \beta^*x_i$

→ funguje lebo μ môže byť akékoľvek číslo ($-\infty$ až $+\infty$)

PROBLÉM:

Čo ak outcome nie je Normálny?

Napr. pravdepodobnosť úspechu $p \rightarrow$ musí byť medzi 0 a 1!

Ak použijeme: $p = \alpha + \beta^*x$

→ lineárna funkcia môže dať $p = 1.5$ alebo $p = -0.3$

→ to nie je platná pravdepodobnosť!

RIEŠENIE = LINK FUNCTION f:

$f(p_i) = \alpha + \beta^*(x_i - \bar{x})$

→ f transformuje p (0,1) na $(-\infty, +\infty)$

→ lineárny model pracuje v neobmedzenom priestore

→ f^{-1} (inverse link) to prevedie späť na (0,1)

GRAF:


Prerušovaná čiara = čo by lineárny model chcel urobiť ($p > 1$)

Plná čiara = čo skutočne môže byť ($p \max = 1$)

→ link function "ohýba" priamku aby zostala v (0,1)

ZÁVER:

GLM = lineárna regresia + iná likelihood + link function



EXPONENCIÁLNA RODINA DISTRIBÚCIÍ:

Všetky tieto distribúcie sú MAXENT pre určité podmienky.

Všetky súvisia s Exponenciálnou distribúciou v strede.

PREHLAD:

EXPONENCIÁLNA:

→ kladné reálne čísla (čas, vzdialenosť)

→ vieš len expected value (λ^{-1})

→ napr. čas čakania na autobus

GAMMA:

→ kladné reálne čísla

→ suma niekoľkých exponenciálnych udalostí

→ napr. čas kým nastane k-tá udalosť

NORMÁLNA:

→ vieš mean a variance

→ suma veľkého množstva Gamma distribúcií

BINOMICKÁ:

→ počet úspechov z n pokusov

→ vieš len p (pravdepodobnosť úspechu)

POISSONOVA:

→ počty udalostí (0, 1, 2, 3...)

→ Binomická kde $n \rightarrow \infty$ a $p \rightarrow 0$


→ vieš len rate λ (priemerný počet udalostí)

→ napr. počet emailov za hodinu

ZÁVER:

Každá distribúcia = maxent pre určitý typ dát a podmienok.

Vyber distribúciu podľa toho čo vieš o svojich dátach.



LINK FUNCTION:

PROBLÉM (recall):

Lineárny model $\alpha + \beta \cdot x$ dáva hodnoty $(-\infty \text{ až } +\infty)$
Ale niektoré parametre majú obmedzený rozsah:
→ pravdepodobnosť: len $(0, 1)$
→ počty: len $(0, \infty)$

LINK FUNCTION = transformácia ktorá to rieši:
Mapuje obmedzený priestor parametra
na neobmedzený priestor lineárneho modelu.

DVE NAJČASTEJŠIE:

LOG link:

→ pre parametre ktoré musia byť Kladné $(0 \text{ až } \infty)$
→ $\log(\theta) = \alpha + \beta \cdot x$
→ $\theta = e^{(\alpha + \beta \cdot x)}$ ← vždy kladné ✓
→ používa sa napr. pre Poissonovu regresiu

LOGIT link:

→ pre parametre ktoré musia byť medzi 0 a 1
→ $\text{logit}(p) = \alpha + \beta \cdot x$
→ $p = 1 / (1 + e^{-(\alpha + \beta \cdot x)})$ ← vždy medzi 0 a 1 ✓
→ používa sa pre logistickú regresiu (Binomická)

LOGIT LINK - logistická regresia:

ČO JE LOGIT?

$\text{logit}(p) = \log(p / (1-p)) = \text{"log odds"}$
= logaritmus pomeru šance úspechu vs neúspechu

Příklad: $p=0.7 \rightarrow \text{logit} = \log(0.7/0.3) = \log(2.33) = 0.85$

MODEL:

$\text{logit}(p_i) = \alpha + \beta \cdot x_i$
→ lineárny model na log-odds škále

INVERSE LOGIT (logistická funkcia):

$p_i = \exp(\alpha + \beta \cdot x_i) / (1 + \exp(\alpha + \beta \cdot x_i))$
→ vždy medzi 0 a 1 ✓

GRAFY:

Ľavý: lineárny vzťah na log-odds škále
Pravý: S-krivka na pravdepodobnostnej škále
→ ďaleko od 0 sa zmeny spomaľujú (kompressia)

PROBLÉM S INTERPRETÁCIOU:

β už nemá priamu interpretáciu!
V lineárnej regresii: β = zmena μ o 1 jednotku x
V logistickej regresii: β = zmena LOG-ODDS o 1 jednotku x
→ ťažšie na pochopenie ale nemáme na výber
→ model zachytáva realitu správne

LOG LINK:

KEDY HO POUŽIŤ?

Keď parameter musí byť Kladný (napr. σ , λ)
→ σ nemôže byť záporné!

MODEL:

$\log(\sigma_i) = \alpha + \beta \cdot x_i$
→ lineárny model na log škále

INVERSE (späť na pôvodnú škálu):

$\sigma_i = \exp(\alpha + \beta \cdot x_i)$ → vždy kladné ✓

GRAFY:





Ľavý: lineárny vzťah na log škále
Pravý: exponenciálna krivka na pôvodnej škále
→ malé zmeny x → veľké zmeny σ pri vyšších hodnotách

INTERPRETÁCIA (opäť zložitejšia):

β = zmena $\log(\sigma)$ o 1 jednotku x
= σ sa zmení EXPONENCIÁLNE (nie lineárne)
→ jednotková zmena x → proporcionálna zmena σ

DÔLEŽITÁ POZNÁMKA:

Log link = akoby sme zaviedli nelineárnu interakciu parametra so sebou samým.
Efekt zmeny závisí od aktuálnej hodnoty parametra.
→ preto je interpretácia zložitejšia ako v lineárnej regresii



GLM - formálna definícia:

$$y \sim \text{pdf}(\mu, [\text{parameters}])$$
$$\mu = f^{-1}(\text{lin}(x), [\text{parameters}])$$

JEDNODUCHO:

1. Vyber distribúciu pre dáta y (pdf)
napr. Normal, Binomial, Poisson...
2. Lineárny model: $\text{lin}(x) = \alpha + \beta^*x$
(pracuje v neobmedzenom priestore)
3. Inverse link function f^{-1} prevedie
lineárny model na správny rozsah pre μ
napr. logistic function $\rightarrow (0,1)$ pre pravdepodobnosť
exponential $\rightarrow (0,\infty)$ pre kladné hodnoty

PRÍKLADY:

Lineárna regresia: $y \sim \text{Normal}$, f^{-1} = identity (žiadna zmena)

Logistická regresia: $y \sim \text{Binomial}$, f^{-1} = logistic function

Poissonova regresia: $y \sim \text{Poisson}$, f^{-1} = exponential

Regressions with Metric and Nominal Predictors

- This is the format of the linear model part (no-link)

Scale type of predictor x					
Metric			Nominal		
Single group	Two groups	Single predictor	Multiple predictors	Single factor	Multiple factors
β_0	$\beta_{x=1}$ $\beta_{x=2}$	$\beta_0 + \beta_1 x$	β_0 $+ \sum_k \beta_k x_k$ $+ \sum_{j,k} \beta_{j \times k} x_j x_k$ $+ \left[\begin{array}{c} \text{higher order} \\ \text{interactions} \end{array} \right]$	$\beta_0 + \vec{\beta} \cdot \vec{x}$	β_0 $+ \sum_k \vec{\beta}_k \cdot \vec{x}_k$ $+ \sum_{j,k} \vec{\beta}_{j \times k} \cdot \vec{x}_{j \times k}$ $+ \left[\begin{array}{c} \text{higher order} \\ \text{interactions} \end{array} \right]$

Source: Table 15.1. John K. Kruschke. *Doing Bayesian Data Analysis*. 2014.

TYPY REGRESÍÍ - prehľad:

METRIC predictors (spojité čísla ako vek, výška, GDP):

- 1 skupina: $\mu = \beta_0$
- 2 skupiny: $\mu = \beta_0 + \beta_1 x$
- 1 prediktor: $\mu = \beta_0 + \beta_1 x$
- viac prediktory: $\mu = \beta_0 + \sum \beta_k x_k + \text{interakcie}$

NOMINAL predictors (kategórie ako kontinent, pohlavie):

- 1 faktor: $\mu = \beta_0 + \vec{\beta} \cdot \vec{x}$ (vektor koeficientov)
- viac faktorov: $\mu = \beta_0 + \sum \beta_k x_k + \text{interakcie}$

TOTO SME UŽ VIDELI V PRAXI:

GDP príklad: metric (ruggedness) + nominal (kontinent)
 $\rightarrow$ interakcia = β závisela od kontinentu

ZÁVER:

Toto je len formálny prehľad všetkých kombinácií
ktoré môžeme mať v lineárnej časti GLM.
V praxi vyberieme kombináciu podľa našich dát.

Typical Noise Distributions and Inverse Link Functions

Scale type of predicted y	Typical noise distribution $y \sim \text{pdf}(\mu, [\text{parameters}])$	Typical inverse link function $\mu = f(\text{lin}(x), [\text{parameters}])$
Metric	$y \sim \text{normal}(\mu, \sigma)$	$\mu = \text{lin}(x)$
Dichotomous	$y \sim \text{bernoulli}(\mu)$	$\mu = \text{logistic}(\text{lin}(x))$
Nominal	$y \sim \text{categorical}(\dots, \mu_k, \dots)$	$\mu_k = \frac{\exp(\text{lin}_k(x))}{\sum_c \exp(\text{lin}_c(x))}$
Ordinal	$y \sim \text{categorical}(\dots, \mu_k, \dots)$	$\mu_k = \frac{\Phi((\theta_k - \text{lin}(x)) / \sigma)}{-\Phi((\theta_{k-1} - \text{lin}(x)) / \sigma)}$
Count	$y \sim \text{poisson}(\mu)$	$\mu = \exp(\text{lin}(x))$

Source: Table 15.2. John K. Kruschke. *Doing Bayesian Data Analysis*. 2014.

CHEAT SHEET - aký GLM použiť:

METRIC (spojitý outcome, napr. výška, GDP):

distribúcia: Normal(μ, σ)

link: identity (žiadna transformácia)

$\mu = \alpha + \beta \cdot x$

DICHOTOMOUS (binárny outcome, napr. áno/nie, 0/1):

distribúcia: Bernoulli(μ)

link: logistic

$\mu = \exp(\text{lin}) / (1 + \exp(\text{lin})) \rightarrow (0,1)$

NOMINAL (kategórie bez poradia, napr. farba, krajina):

distribúcia: Categorical

link: softmax

$\mu_k = \exp(\text{link}) / \sum \exp(\text{link}) \rightarrow \text{suma} = 1$

ORDINAL (kategórie s poradím, napr. hodnotenie 1-5):

distribúcia: Categorical

link: kumulatívna normálna (Φ)

COUNT (počty, napr. počet emailov):

distribúcia: Poisson(μ)

link: exponential

$\mu = \exp(\alpha + \beta \cdot x) \rightarrow$ vždy kladné

ZÁVER:

Pozri sa na outcome $\rightarrow$ vyber riadok $\rightarrow$ máš model.

