

Mini Projekt – Študijný sprievodca na exam

Tento dokument prechádza náš mini projekt sekciu po sekcii: čo sme robili, prečo, a ako to súvisí s učebnou látkou (L1-L13). Na skúške sa môžu pýtať na ktorúkoľvek z týchto vecí.

0. O čom je celý projekt

Dataset: C programy vygenerované rôznymi LLM (9 modelov: llama2, gemini_pro, gpt35, falcon, gpt4o_mini, gemma, falcon2, mistral, codellama). Každý program bol formálne overený na bezpečnostné zraniteľnosti (buffer overflow, invalid memory dereference, atď.).

Dve hypotézy:

- **H1:** llama2 produkuje menej zraniteľný kód ako každý iný LLM v datasete.
- **H2:** väčšia cyclomatic complexity (CC) súvisí s väčším počtom riadkov kódu (LOC), a tento vzťah platí pre všetky LLM.

Prečo Bayes: celý kurz je o Bayesovskej štatistike – nepýtame sa "áno/nie", ale počítame posterior distribúciu parametrov a vyjadrujeme **neistotu** cez HDI intervaly. To je rozdiel oproti klasickej frekventistickej štatistike (p-hodnoty).

HYPOTÉZA 1 – Logistická regresia

1.1 Výber modelu: prečo logistická regresia?

Čo sme robili: outcome je binárny ($\text{VULNERABLE} = 1, \text{NON-VULNERABLE} = 0$). Použili sme logistickú regresiu.

Prečo: binárny outcome sa nedá modelovať obyčajnou lineárnou regresiou – tá by mohla predikovať pravdepodobnosť > 1 alebo < 0 . Potrebujeme GLM s Bernoulli likelihood a **logit link function**, ktorá zabezpečí že p ostane v $(0,1)$.

Súvis s látkou: L8 (GLM). Presne to čo sme sa učili – binárny/dichotomous outcome → Bernoulli distribúcia → logit link. Model:

```
Y_i ~ Bernoulli(p_i)
logit(p_i) = α + β_LLM[i]
```

1.2 Data cleaning

Čo sme robili: odstránili sme programy kde výsledok bol nejasný (parsing errors, verification timeouts). Nechali sme len VULNERABLE a NON-VULNERABLE riadky.

Prečo: nespoľahlivé labels by skreslili odhad. Toto je štandardný a nutný krok.

Súvis s látkou: dáva sa to dať pod **survivorship bias / conditioning (L6)** - pozor na to, na čom kondicionujeme dáta. Tu je to ale neškodné, lebo nejasné výsledky nesúvisia s tým ktorý LLM ich vyprodukoval.

1.3 Dva spôsoby zakódovania: index-coded vs reference-coded

Toto je **klúčová časť** a pýtali sa na to skoro určite.

Index-coded model

Čo: každý LLM dostane vlastný koeficient β_j . α je globálny intercept, β_j je odchýlka LLM j od priemeru na log-odds škále.

$$\text{logit}(p_i) = \alpha + \beta_{\text{LLM}[i]}$$

Na čo: dobré na **porovnanie všetkých LLM naraz**, každý je rovnocenný.

Reference-coded model

Čo: llama2 je referenčná kategória. α = log-odds zraniteľnosti pre llama2. Každý β_k = rozdiel medzi LLM k a llama2.

$$\text{logit}(p_i) = \alpha + \sum \beta_k \cdot x_{ik}$$

Na čo: priamo testuje hypotézu - ak je 95% HDI koeficientu celé nad nulou, ten LLM je horší ako llama2.

Dôležité: oba modely sú **matematicky ekvivalentné reparametrizácie** tej istej logistickej regresie → musia dať rovnaký záver. Robíme oba lebo každý lepšie ukazuje inú vec.

Súvis s látkou: **index coding** je presne to z **L6 (interactions / index models)** a **L3 (categorical variables)**. Reference coding = dummy coding, tiež L3/L8 (viď Kruschke tabuľka nominal predictors v L8).

1.4 Priors

Čo sme robili: $\alpha \sim \text{Normal}(0, 1)$ a $\beta \sim \text{Normal}(0, 1)$.

Prečo: na log-odds škále je $\text{Normal}(0,1)$ **weakly informative** (slabo informatívny) prior. Nepredpokladá vopred že LLM sú bezpečné alebo nebezpečné, ale obmedzuje koeficienty na rozumný rozsah → funguje ako regularizácia.

Súvis s látkou: **L5 (regularization)** - prior ako regularizér. Úzky prior ($\text{Normal}(0,1)$) znižuje riziko overfittingu oproti širokému (napr. $\text{Normal}(0,100)$). Aj **L8 (maximum entropy)** - Normal

je maxent voľba keď poznáme mean a varianciu.

1.5 Sampling

Čo sme robili: `pm.sample(draws=2000, tune=1000, chains=4, random_seed=42)`.

Prečo tieto nastavenia:

- **chains=4** - viac nezávislých chainov nám umožní skontrolovať konvergenciu (R-hat porovnáva chainy medzi sebou).
- **tune=1000** - warmup/burn-in. PyMC používa NUTS (HMC), počas warmupu si nastaví parametre ϵ a τ . Tieto samples sa zahadzujú.
- **random_seed=42** - reprodukovateľnosť (MCMC je náhodný algoritmus).

Súvis s látkou: L7 (MCMC) celá. PyMC interne používa NUTS = No-U-Turn Sampler, čo je variant HMC. Warmup = burn-in/tune z L7.

1.6 Hypothesis discussion - ako sme odpovedali na hypotézu

Čo sme robili: najprv forest plot koeficientov. Potom sme spočítali $P(\beta_{\text{llama2}} < \beta_k)$ pre každý iný LLM - teda v koľkých posterior samples má llama2 nižší koeficient.

Prečo takto: hypotéza nie je o bodovom odhade, ale o pravdepodobnosti. Bayesovský prístup nám umožní povedať priamo "s pravdepodobnosťou 0.99 je llama2 bezpečnejší ako gpt35". To je sila Bayesa oproti frekventizmu.

Výsledky:

- Silný dôkaz (≥ 0.95) že llama2 je bezpečnejší ako 5 z 8 LLM.
- gemma (0.76), mistral (0.87), codellama (0.94) - nejasné.
- $P(\text{llama2 safer than ALL}) = 0.66$ - lebo to vyžaduje aby VŠETKY porovnania platili naraz, a neistota okolo gemma/mistral/codellama to stiahne dole.

Záver H1: čiastočne podporená. llama2 je bezpečnejší ako väčšina, ale nie preukázateľne ako všetky.

Súvis s látkou: používanie posterior samples na výpočet pravdepodobností je základ Bayesian inference (L1). HDI intervaly tiež.

1.7 Diagnostika konverencie

Čo sme robili: trace plots + R-hat + ESS (cez `az.summary`).

Na čo slúži každý:

- **Trace plot** – ak chains "skáču" náhodne a prekrývajú sa = dobrý mixing, konvergencia. "Chlpatá húsenica" = dobré.
- **R-hat** – porovnáva varianciu medzi chains vs vnútri chains. ≈ 1.0 = konvergované. Naše hodnoty boli všetky ≈ 1.00 ✓
- **ESS** – koľko skutočne nezávislých samples máme. Naše boli 2500-6000+, čiže vysoké ✓

Súvis s látkou: L7 (diagnostika MCMC) – presne trace plots, R-hat, ESS. R-hat < 1.01 = ok (pravidlo z L7).

1.8 Prior predictive check

Čo sme robili: pred fitovaním sme vygenerovali dáta len z priorov a pozreli aké pravdepodobnosti p model považuje za možné.

Výsledok: distribúcia p bola zhruba uniformná na (0,1) → prior nepreferuje žiadny outcome dopredu. Presne čo chceme od weakly informative prioru.

Prečo to robíme: overiť že priors sú rozumné PREDTÝM ako uvidíme dáta. Ak by prior predictive dával nezmysly (napr. všetko $p \approx 0$), priors sú zlé.

Súvis s látkou: súčasť Bayesovského workflow (**L1, L2**). Aj kontrola regularizácie (**L5**).

1.9 Posterior predictive check

Čo sme robili: po fitovaní sme vygenerovali simulované outcomes z modelu a porovnali predikovanú vulnerability rate s pozorovanou (červený bod) pre každý LLM.

Výsledok: pozorovaná rate padla do hustého streda predikovanej distribúcie pre každý LLM → model dobre reprodukuje dáta.

Prečo: overiť že model je **štruktúrálné adekvátny** – že vôbec vie zachytiť dáta. Bez toho by hypotézový test nemal zmysel.

Detail: LLM s viac programami majú užší cloud (menšia neistota), s menej programami širší. To dáva zmysel – viac dát = istejší odhad.

Súvis s látkou: posterior predictive check je štandardný Bayesovský nástroj (**L1, L5** – súvisí s tým ako model predikuje nové dáta, podobne ako LOO/WAIC myšlienka).

HYPOTÉZA 2 – Hierarchický (multilevel) lineárny model

2.1 Výber modelu: prečo hierarchická regresia?

Čo sme robili: každý LLM dostal vlastný intercept α_j aj slope β_j , oba ťahané zo zdieľanej populačnej distribúcie.

```
log(CC)_i ~ Normal( $\mu_i$ ,  $\sigma$ )
 $\mu_i = \alpha_{LLM[i]} + \beta_{LLM[i]} \cdot z_i$ 
 $\alpha_j \sim \text{Normal}(\mu_\alpha, \sigma_\alpha)$ 
 $\beta_j \sim \text{Normal}(\mu_\beta, \sigma_\beta)$ 
```

Prečo hierarchicky a nie 9 separátnych regresíí: LLM s málo programami si "požičiavajú silu" od populácie (shrinkage), LLM s veľa dátami sa spoliehajú na vlastné dáta. Jeden spoločný model = lepšie odhady + môžeme merať populačný trend.

Súvis s látkou: L12 (Multilevel models) priamo. α_j a β_j z populačnej distribúcie = partial pooling. Toto je presne reed-frogs/šimpanzy príklad ale aplikovaný na LLM. Slope β je kľúčový parameter (ako v interakčných modeloch z L6).

2.2 Log transformácia a štandardizácia

Čo sme robili: $y = \log(CC)$, $z = (\log(LOC) - \text{mean}) / \text{std}$.

Prečo log: LOC aj CC sú right-skewed (veľa malých hodnôt, pár veľkých). Log to skomprimuje a urobí vzťah lineárnejším. Navyše CC aj LOC rastú multiplikatívne, nie aditívne.

Prečo štandardizácia LOC: centrovanie + škálovanie → intercept α dostane zmysel (= $\log(CC)$ pri priemernom LOC) a PyMC sampleuje efektívnejšie.

Súvis s látkou: L6 (centering) - prečo centrujeme aby mal intercept zmysel. Log transformácia outcome súvisí s GLM myšlienkou z L8 (aj keď tu robíme log ručne, nie cez link).

2.3 Dva likelihoody: Normal vs TruncatedNormal

Čo sme robili: dva modely.

- Normal:** $\log(CC) \sim \text{Normal}(\mu, \sigma)$ - štandard.
- TruncatedNormal:** $\log(CC) \sim \text{TruncatedNormal}(\mu, \sigma, \text{lower}=0)$ - tvrdá hranica na nule.

Prečo TruncatedNormal: $CC \geq 1$ vždy, takže $\log(CC) \geq 0$ vždy. Normal môže predikovať záporné $\log(CC)$ čo je nemožné. TruncatedNormal to opraví.

Prečo oba: TruncatedNormal je **robustness check** - ak oba modely dajú rovnaký záver, sme si istejší výsledkom.

Súvis s látkou: voľba správnej likelihood = L8 (GLM). Robustness check myšlienka súvisí aj s L5 (robust regression / Student-t) - tam sme tiež menili likelihood (Normal → Student-t) aby model lepšie sedel na realitu. Tu meníme Normal → TruncatedNormal z podobného dôvodu.

2.4 Priors (H2)

Čo sme robili: `Normal(0, 1)` pre hyperparametre (μ_α, μ_β), `HalfNormal(1)` pre scale parametre ($\sigma_\alpha, \sigma_\beta, \sigma$).

Prečo: po log+štandardizácii sú dáta na malej škále, takže `Normal(0,1)` pokrýva rozumný rozsah. `HalfNormal` pre σ lebo **scale parametre musia byť kladné**.

Súvis s látkou: L5 (regularization / priors). `HalfNormal` pre kladné parametre súvisí s **L8 (log link pre kladné parametre)** – iný spôsob ako vynútiť kladnosť.

2.5 Sampling a divergencie (DÔLEŽITÉ)

Čo sme robili:

- Normal model: `tune=2000, target_accept=0.99` → 0 divergencií.
- TruncatedNormal: najprv `tune=2000` → **7 divergencií**. Zvýšili sme na `tune=4000` → divergencie zmizli.

Prečo divergencie pri TruncatedNormal: tvrdá hranica na nule vytvára **ostrú geometriu** posterioru. HMC simulácia tam "vyletí" → divergencia.

Prečo pomohlo target_accept=0.99 + viac tune: vyšší target_accept = menší step size ϵ → presnejšia simulácia → menej divergencií. Viac tune = HMC má viac času nastaviť si parametre.

Súvis s látkou: L7 (HMC, divergencie) a L12 (divergent transitions, ako ich opraviť). POZOR: v L12 sme sa učili že lepšie riešenie divergencií je často **non-centered reparametrizácia**, nie len zvyšovanie target_accept. To by sa dalo spomenúť na skúške ako "čo sme mohli urobiť lepšie".

2.6 Diagnostika (H2)

Čo sme robili: R-hat, ESS, trace plots, **autocorrelation plots**.

Výsledky: R-hat = 1.0 všade, ESS > 5000, autocorrelation padá k nule hneď po lag 1 → výborný mixing.

Autocorrelation plot navyše: meria koreláciu medzi susednými samples. Rýchly pokles k nule = samples sú nezávislé = dobré.

Súvis s látkou: L7 – autocorrelation a ESS sú priamo odtiaľ. Nízka autokorelácia → vysoký ESS.

2.7 Hypothesis discussion (H2)

Čo sme robili: pozreli sme β (slope) pre každý LLM. Ak je 95% HDI celé nad nulou → vzťah LOC→CC je jasne pozitívny pre ten LLM.

Výsledky: len 4 z 9 LLM majú jasne pozitívny slope (llama2, gemini_pro, gpt35, gemma). Ostatných 5 má HDI cez nulu. Falcon má dokonca záporný priemer.

Záver H2: NEPODPORENÁ. Hypotéza vyžaduje aby vzťah platil pre VŠETKY LLM, čo neplatí. Oba modely (Normal aj Truncated) dali rovnaký záver → robustné.

Súvis s látkou: interpretácia slope koeficientu a HDI = $L1/L2$ (**Bayesian regression**). Testovanie "platí pre všetky skupiny" je presne myšlienka **interakcie (L6)** – či efekt LOC závisí od LLM.

CELKOVÝ ZÁVER PROJEKTU

- **H1 čiastočne podporená:** llama2 bezpečnejší ako väčšina LLM, ale nie preukázateľne ako všetky.
 - **H2 nepodporená:** vzťah LOC→CC neplatí konzistentne pre všetky LLM.
-

ČO BY SA MOHLI PÝTAŤ NA SKÚŠKE (a čo nemá priamy súvis s látkou)

Pravdepodobné otázky:

1. *Prečo logistická regresia pre H1?* → binárny outcome, GLM + logit link (L8).
2. *Aký je rozdiel medzi index-coded a reference-coded?* → ekvivalentné reparametrizácie, jeden na porovnanie všetkých, druhý na priame testovanie vs referencia (L3/L6).
3. *Čo je shrinkage a prečo hierarchický model?* → partial pooling, malé skupiny si požičiavajú silu (L12).
4. *Prečo divergencie a ako ich riešiť?* → ostrá geometria, target_accept / non-centered (L7, L12).
5. *Načo prior/posterior predictive check?* → overenie priorov pred dátami a fitu modelu po dátach (L1, L5).
6. *Prečo log transformácia a centrovanie?* → skew + zmysluplný intercept (L6, L8).
7. *Čo je R-hat / ESS / autocorrelation?* → diagnostika konvergencie MCMC (L7).

Veci ktoré NEMAJÚ priamy súvis s prebranou látkou (treba priznať ak sa pýtajú):

- **TruncatedNormal distribúcia** – konkrétne túto sme v lekciách explicitne nepreberali. Logika je ale rovnaká ako Student-t robust regression (L5) a voľba likelihood (L8).
- $P(\beta_{llama2} < \beta_k)$ **výpočet cez porovnanie posterior samples** – tento konkrétny "pairwise probability" prístup nebol priamo v lekciách, ale vyplýva zo základov Bayesian inference (L1) – že máme celú posterior distribúciu a môžeme z nej počítat ľubovoľné pravdepodobnosti.
- **Cyclomatic complexity ako pojem** – to je software engineering metrika, nie štatistika. Netreba ju vedieť štatisticky, len že je to náš outcome.

RÝCHLA TABUĽKA: SEKCIA → LEKCIA

Sekcia projektu	Súvisiaca lekcia
Bayesian workflow, posterior, HDI	L1
Lineárna/logistická regresia	L2
Categorical / dummy / index coding	L3, L6
Regularization cez priors	L5
Robustness check (zmena likelihood)	L5
Centering, interakcie, index model	L6
MCMC, NUTS, burn-in, R-hat, ESS, autocorr, divergencie	L7
GLM, logit link, voľba likelihood, maxent priors	L8
(Binárny outcome = logistická regresia)	L10
Hierarchický model, shrinkage, partial pooling	L12
Non-centered ako fix divergencií	L12